



Master Économiste de l'entreprise - Université de Tours
2024-2025

RECHERCHE, RÉALISATION, RÉSTITUTION

Attrition, Valeur Client et Portefeuille

Etude de la valorisation du client

Réalisé par
Hugo COCHEREAU et Gregory JAILLET

Dirigé par
M. Alain BOUSQUET

Date
Décembre 2024

TABLE DES MATIÈRES

PARTIE 1	LA VALORISATION DU CLIENT	PAGE 6
	La Valeur Vie Client	6
	Modélisation de la CLV	7
	Les concepts à prendre à compte	9
	Des Modèles différents	11
	Les Modèles RFM	11
	Modèles probabilistes	12
	Les modèles de persistance	13
	Les modèles de diffusion/croissance	14
	Modèles Acquisition, de Rétention et Expansion	15
	Customer Acquisition	15
	Customer Retention	16
	Customer Margin and Expansion	20
PARTIE 2	PRÉSENTATION DE NOTRE ÉTUDE	PAGE 22
	Base de Données : Telco	22
	Méthodologie	24
PARTIE 3	ANALYSE DESCRIPTIVE	PAGE 27
	Etude des variables catégorielles	28
PARTIE 4	MODÉLISATION ÉCONOMÉTRIQUE	PAGE 30
	Introduction	30
	Sélection du modèle	30

Hypothèses à vérifier	36
Les risques sont-ils proportionnels ?	37
Résidus de Schoenfeld	41
Cas 1 : Etude pré-intégration	43
Sélection de la distribution	44
Analyse des résultats	49
Estimations de la valeur des clients	50
Cas 2 : Les clients signent un contrat avec la compagnie	53
Sélection du modèle	58
Sélection de la distribution	59
Analyse des résultats	63
Cas 3 : Etude Post-intégration	67
Analyse des résultats	71
Conclusion	76

PARTIE 5

ANALYSE DE SURVIE PAGE 77

Introduction	77
Modèles de durée	78
Espérance de vie et variance	79
Censure et troncature	79
Modèles non-paramétriques	81
Modèles paramétriques	82
Modèle de Cox	88
Brève présentation des outils disponibles	90
Sur R	90
Sur python	91

PARTIE 6

RÉFÉRENCES BIBLIOGRAPHIQUES PAGE 92

Liste des Figures

1	Cadre conceptuel de la CLV	7
2	Random Survival Forest	18
3	Les risques sont-ils proportionnels ?	38
4	Les risques sont-ils proportionnels ?	38
5	Les risques sont-ils proportionnels ?	39
6	Les risques sont-ils proportionnels ?	39
7	Les risques sont-ils proportionnels ?	40
8	Les risques sont-ils proportionnels ?	40
9	Cas 1 : Loi Exponentielle (PH et AFT)	44
10	Cas 1 : Loi Weibull (AFT)	45
11	Cas 1 : Loi Log-Logistique (AFT)	46
12	Cas 1 : Loi Log-Normale (AFT)	46
13	Cas 1 : Loi Gamma Généralisée (AFT)	47
14	Cas 1 : Loi Fisher Généralisée (AFT)	47
15	Cas 1 : Comparaison observation/prédiction	50
16	Cas 1 : Estimations du modèle	51
17	Etude des Dimensions	55
18	Etude des contributions à l'axe 1	55
19	Etude des contributions aux axes 2 et 3	56
20	ACM - Biplot	56
21	ACM - Biplot	57
22	Cas 2 : Loi Exponentielle (PH et AFT)	59
23	Cas 2 : Loi Weibull (AFT)	59
24	Cas 2 : Loi Log-Logistique (AFT)	60
25	Cas 2 : Loi Log-Normale (AFT)	60
26	Cas 2 : Loi Gamma Généralisée (AFT)	61

27	Cas 2 : Loi Fisher Généralisée (AFT)	61
28	Cas 2 : Comparaison observation/prédiction	65
29	Cas 2 : Estimations du modèle	65
30	Cas 3 : Loi Exponentielle (PH et AFT)	67
31	Cas 3 : Loi Weibull (AFT)	68
32	Cas 3 : Loi Log-Logistique (AFT)	68
33	Cas 3 : Loi Log-Normale (AFT)	69
34	Cas 3 : Loi Gamma Généralisée (AFT)	69
35	Cas 3 : Loi Fisher Généralisée (AFT)	70
36	Cas 3 : Comparaison observation/prédiction	73
37	Cas 3 : Estimations du modèle	73
38	Représentation des types de censures possibles dans les études de survie. .	81

Liste des Tables

1	Tableau récapitulatif des modèles de valorisation client	21
4	Performance des Modèles : Avant la signature d'un contrat	48
6	Cas 1 : Modèle AFT à distribution log-normale	49
9	Performance des Modèles : Après la signature d'un contrat	62
15	Performances des Modèles : Après l'enquête de satisfaction	70

La valorisation du Client

La Valeur Vie Client

Ce qui détermine la valeur d'une entreprise réside principalement dans son portefeuille client, ou plus précisément dans la valeur qu'il représente. Mais une question essentielle se pose : comment mesurer et valoriser un client ? Cette interrogation, au cœur des préoccupations de tout dirigeant d'entreprise, mérite une réflexion approfondie. Ce document ambitionne d'apporter des éléments de réponse à cette problématique complexe.

Pour cela, nous explorerons le concept de la **Customer Lifetime Value** (CLV), un indicateur clé permettant d'évaluer la valeur qu'un client apporte à une entreprise tout au long de sa relation avec celle-ci.

La Customer Lifetime Value (ou Valeur Vie Client) est, comme mentionné dans l'introduction, un indicateur, pouvant être une valeur monétaire concrète ou même un score, permettant de mesurer la valeur d'un client pour une entreprise.

Sunil Gupta et Donald R. Lehmann (2003) définissent la CLV comme la valeur actuelle nette des profits futurs générés par un client sur la durée de relation que celui-ci entretient avec l'entreprise.

Au-delà de permettre l'estimation de la valeur d'un client, la CLV peut aussi être utilisée afin de mettre en place des stratégies marketing plus efficaces, en identifiant les clients les plus rentables et en ciblant les efforts marketing sur ces derniers.

Modélisation de la CLV

Le modèle de base de la CLV est souvent exprimé via une Valeur Actuelle Nette ou “Net Present Value” (NPV) des flux de trésorerie liés à un client. Cette approche, bien que simple, fournit une estimation de base utile, mais elle peut être enrichie par des modèles plus complexes prenant en compte des éléments supplémentaires comme le taux de rétention, le coût d’acquisition client (AC). Afin d’estimer la CLV Sunil Gupta, Dominique Hanssens, Bruce Hardie, William Kahn, V. Kumar, Nathaniel Lin, Nalini Ravishanker et S. Sriram (2006) propose le cadre conceptuel suivant :




Figure 1 – Cadre conceptuel de la CLV

où le capital client ou “**Customer equity**” (CE) est défini comme la somme des valeurs actuelles des profits futurs générés par l’ensemble des clients de l’entreprise (EsmaeiliGookeh et M. J. Tarokh (2013)).

Ce cadre conceptuel permet de décomposer la CLV en plusieurs composantes :

- Nous devons prendre en compte le contexte d’**acquisition** d’un client, c’est-à-dire la première période de relation avec l’entreprise, qu’est-ce qui a pu attirer ce client mais aussi le coût d’acquisition de ce dernier.
- La **rétention** client est un élément clé de la CLV, car elle permet de modéliser le comportement des clients au fil du temps. Un client fidèle et récurrent générera plus de valeur qu’un client qui ne reste que peu de temps.
- Enfin, il faut aussi évoquer les **revenus générés** par le client et la nature de ces revenus, un client a-t-il acheté plusieurs fois le même produit ? est-ce qu’il a généré des revenus en achetant plusieurs produits différents (cross-selling) ou achetant des gammes supérieures (up-selling) ?

Ces différentes composantes permettent de modéliser la CLV de manière plus précise et de mieux comprendre les facteurs qui influent sur la valeur des clients pour l'entreprise, Gupta S., Donald R. Lehmann et Jennifer Ames Stuart (2004); proposent la modélisation suivante :

$$CLV = \sum_{t=1}^T \frac{(R_t - C_t)r_t}{(1 + d)^t} - AC$$

où :

- T est la durée de vie du client
- R_t est le revenu généré par le client à la période t
- C_t est le coût généré par le client à la période t
- d est le **taux d'actualisation** compris entre 0 et 1 fixé par le statisticien, une valeur basse va donner plus de poids aux revenus futurs donc une vision de long terme, une valeur haute va donner plus de poids aux revenus actuels donc une vision de court termiste
- r_t est le taux de rétention du client à la période t , c'est à dire la probabilité que le client reste actif à la période t sachant qu'il était actif à la période $t - 1$, c'est ce qui va modéliser l'éventuelle variabilité dans le comportement du consommateur
- AC est le coût d'acquisition du client, on pourrait tout simplement penser a une dépense publicitaire

L'estimation du taux de rétention permet la prise en compte des comportement futurs des clients. Nous pourrions modéliser ces comportements au travers l'**analyse de survie** des clients ou en encore en usant des modèles de **Markov** offrant une formalisation des transitions entre différents états d'un client (actif, inactif, réactivé).

Cette modélisation de la CLV démontre que les entreprises peuvent adopter un grand nombre de stratégies dans le but de maximiser leur rentabilité. Retenir tous les clients n'est pas nécessairement la meilleure approche, car certains clients peuvent présenter un risque élevé malgré leur potentiel de génération de valeur, maximiser le taux de rétention ne représente pas nécessairement une stratégie viable. On remarque aussi que les clients générant des revenus élevés à chaque période ne sont pas nécessairement les mieux valorisés car il est possible que le coût de leur acquisition soit lui aussi très élevés. De plus, des stratégies telles que le **cross-selling**⁽¹⁾ et l'**up-selling**⁽²⁾ peuvent être appliquées pour augmenter la valeur des clients existants, mais leur efficacité dépendra de la capacité de l'entreprise à identifier les segments les plus rentables. L'impact des stratégies marketing sur ces composantes doit être soigneusement évalué, et c'est à l'entreprise de déterminer quelles approches sont les plus judicieuses. Enfin, il ne faut négliger l'importance de l'**horizon temporel** choisi par l'entreprise ainsi que le choix du taux d'actualisation, en effet, il est nécessaire de se demander si les revenus potentiels générés par les clients dans un futur lointain sont réellement à prendre en compte

⁽¹⁾Le cross-selling consiste à proposer à un client un produit ou service complémentaire à celui qu'il a déjà acheté.

⁽²⁾L'up-selling consiste à proposer à un client un produit ou service plus cher ou plus sophistiqué que celui qu'il a déjà acheté.

pour pouvoir calculer la valeur des clients, de plus, le choix du taux d'actualisation permettra à l'entreprise de déterminer la valeur actuelle de ces profits futurs.

Ces différentes questions s'accompagne de l'interrogation sur les méthodes utilisés pour modéliser chaque composantes, la littérature en propose une large gamme.

Les concepts à prendre à compte

Le concept de loyauté :

- La fidélité client se divise en deux approches principales, longitudinale et la comportementale. Alors que la première se concentre sur les attitudes et préférences des clients, la seconde mesure les comportements réels d'achat, une approche privilégiée dans les recherches empiriques car elle est plus facilement mesurable à grande échelle (Zhang, Q. J., Dixit, A. et Friedmann, R. (2010)). L'analyse des comportements d'achat permet ainsi de segmenter les clients en fonction de leur fidélité réelle, identifiant ceux qui sont à haut potentiel et nécessitent un effort de fidélisation soutenu.

Le concept de relation contractuelle ou non-contractuelle :

- Une relation contractuelle est une relation où le client est engagé par un contrat (par exemple un contrat d'assurance), une relation non-contractuelle est une relation où le client n'est engagé en rien (par exemple faire ses courses). La distinction entre relations contractuelles et non-contractuelles a donc des implications non-négligeables dans la mise en place des modèles de CLV. Par exemple, dans le cas d'une relation contractuelle le calcul du taux de rétention s'en retrouve facilité. En revanche, dans un contexte non-contractuel, les clients peuvent devenir inactifs sans avertissement, rendant la prédiction de leur comportement plus complexe.

L'effet de concurrence :

- La dimension concurrentielle est difficilement intégrable dans les modèles de CLV, car elle dépend de facteurs externes à l'entreprise, comme les actions des concurrents, les tendances du marché, ou les événements imprévus. Malheureusement, il est difficile de recueillir des données sur ces facteurs et de les intégrer dans les modèles de CLV. Cependant, il est important de garder à l'esprit que la valeur d'un client dépend également de son comportement par rapport à la concurrence, et que les entreprises doivent prendre en compte ces facteurs au moment d'estimer la valeur de leurs clients.

L'effet de bouche à oreille :

- L'effet bouche à oreille est un élément important à prendre en compte dans les modèles de CLV, car il peut avoir un impact significatif sur la valeur des clients. Les clients satisfaits sont plus susceptibles de recommander l'entreprise à leur entourage, ce qui peut entraîner une augmentation des ventes et de la fidélité client. Les entreprises doivent donc chercher à maximiser l'effet bouche à oreille en offrant un service de qualité et en fidélisant leurs clients existants. Villanueva, Julian, Shijin Yoo, & Dominique Villanueva, Julian, Shijin Yoo, et Dominique M. Hanssens (2006) ont constaté que les acquisitions de clients induites par le marketing sont plus rentables à court terme, tandis que les acquisitions par le bouche-à-oreille génèrent des performances plus lentement, mais finissent par devenir deux fois plus précieuses pour l'entreprise.

les approches "lost for good" et "always a share" :

- L'approche "lost for good" (perdu pour toujours) suppose que les clients perdus ne reviendront jamais et elle est souvent critiquée pour cette raison, tandis que l'approche "always a share of wallet" (toujours une part de marché) considère que les clients partis reviendront à un moment donné. Ces deux approches ont des implications différentes pour la CLV, car elles supposent des comportements de défection très différents.

Des Modèles différents

Les Modèles RFM

Les Modèles **RFM** (pour Recency, Frequency, Monetary value) sont des outils, différents des modèles CLV, utilisés pour segmenter et cibler les clients en fonction de leur comportement d'achat passé. Ces modèles permettent aux entreprises de mieux comprendre et de prédire le comportement futur des clients, en se basant sur trois dimensions clés : la **récence** (R), la **fréquence** (F) et la **valeur monétaire** (M).

- **Recency (Récence)**: Désigne la date du dernier achat. La récence mesure combien de temps s'est écoulé depuis le dernier achat du client. Un client qui a acheté récemment est souvent considéré comme plus engagé et plus susceptible d'acheter à nouveau.
- **Frequency (Fréquence)**: Désigne le nombre d'achats effectués. La fréquence mesure combien de fois un client a acheté des produits ou services au cours d'une période donnée. Un client qui achète fréquemment est généralement plus fidèle et plus précieux pour l'entreprise.
- **Monetary value (Valeur monétaire)**: Désigne le montant total dépensé. La valeur monétaire mesure le montant total des achats effectués par un client. Un client qui dépense beaucoup est souvent considéré comme plus rentable.

En classant les clients en groupes ou "cellules" basés sur ces variables, les entreprises peuvent prioriser leurs efforts marketing pour maximiser les taux de réponse. Par exemple, les clients avec une récence élevée, une fréquence élevée et une valeur monétaire élevée sont souvent les plus précieux et méritent des efforts marketing supplémentaires.

Dans l'article de Fader, Peter S. et Ka Lok Lee (2005), les auteurs proposent un modèle qui lie RFM et CLV, segmentant les clients en 125 groupes en fonction de leur score RFM (5 niveaux pour chaque critère). Cette segmentation aide à prioriser les actions marketing en fonction du comportement historique des clients, améliorant ainsi l'efficacité des campagnes.

Le modèle de Weighted-RFM (W-RFM) ajuste ces trois critères avec des poids spécifiques pour chaque dimension :

$$IC_j = w_R C_R + w_F C_F + w_M C_M$$

Où :

- IC_j est le score RFM pondéré pour l'individu j ,
- C_R , C_F , et C_M représentent les scores pour la récence, la fréquence, et la valeur monétaire,
- w_R , w_F , et w_M sont les poids attribués à chaque dimension, définis par l'entreprise en fonction de son domaine d'activité.

Ces modèles présentent cependant certaines limites :

- Ils ne prédisent le comportement des clients que pour la période suivante, alors que la CLV nécessite une estimation sur plusieurs périodes.
- Les variables RFM ne sont que des indicateurs imparfaits du comportement réel des clients, et ne tiennent pas compte de la distribution sous-jacente des données.
- Ils ne prennent pas en compte le fait que le comportement passé des clients peut être influencé par les actions marketing de l'entreprise.
- Les modèles RFM ne fournissent pas de valeur monétaire explicite pour la valeur du client, mais ils restent des variables importantes pour prédire le comportement futur des clients.

Modèles probabilistes

Ce type de modèle vise à prévoir le comportement futur d'un client dans une relation non-contractuelle avec l'entreprise, c'est-à-dire une relation où le client peut cesser ses achats à tout moment sans formalité. Pour y parvenir, le modèle, basé sur des probabilités, interprète le comportement observé comme le résultat d'un processus stochastique influencé par des caractéristiques individuelles latentes (non observables) qui varient d'un client à l'autre. Par exemple, le modèle Pareto/NBD estime la probabilité qu'un client soit encore actif et prévoit ses transactions futures, en utilisant comme informations-clés la « récence » (date du dernier achat) et la « fréquence » (nombre d'achats dans une période donnée), en utilisant cette méthode Fader, Peter S., Bruce G. S. Hardie, et Paul D. Berger (2004) propose la modélisation suivante :

$$CLV(\delta|r, \alpha, s, \beta, p, q, \gamma, x, t_x, T) = \frac{\alpha^r \beta^s \delta^{s-1} \Gamma(r+x-1) \Psi(s, s; \delta(\beta+T))}{\Gamma(r)(\alpha+T)^{r+x+1} L(r, \alpha, s, \beta|x, t_x, T)} \cdot \frac{(\gamma+m_x)p}{px+q-1}$$

La distinction entre relations contractuelles et non-contractuelles a des implications importantes pour ces modèles. Dans une relation contractuelle, l'entreprise sait quand

un client met fin à son contrat, facilitant ainsi les prédictions de comportement. En revanche, dans un contexte non-contractuel, les clients peuvent devenir inactifs sans avertissement, rendant la prédiction de leur comportement plus complexe. Le modèle Pareto/NBD est bien adapté aux contextes non-contractuels où les transactions peuvent se produire de manière continue, mais il devient moins pertinent pour des relations où les achats sont limités à des intervalles fixes (par exemple, événements annuels), où des modèles alternatifs comme le modèle beta-binomial/beta-géométrique sont plus appropriés.

Les modèles de persistance

Ces types de modèles se concentrent aussi sur les trois composantes en considérant un système dynamique selon lequel, les efforts réalisés par l'entreprise pour impacter une des trois composantes peuvent impacter directement ou indirectement les autres composantes. Par exemple, une campagne marketing visant à augmenter la fréquence d'achat des clients peut également avoir un impact sur la rétention et la valeur monétaire des clients. Ces modèles permettent de mieux comprendre les interactions entre les différentes composantes de la CLV et d'identifier les leviers les plus efficaces pour augmenter la valeur des clients. Dekimpe, Marnik et Dominique M. Hanssens (2004) proposent un modèle qui s'opère sur 3 étapes :

1. On considère un système dynamique comportant différentes variables modélisant les trois composantes et on les observe sur une période donnée.
2. On estime un modèle à vecteurs autorégressifs (VAR) à partir des moindres carrés, par exemple :

$$\begin{bmatrix} AM_t \\ AW_t \\ V_t \end{bmatrix} = \begin{bmatrix} \alpha_{11} & \alpha_{12} & \alpha_{13} \\ \alpha_{21} & \alpha_{22} & \alpha_{23} \\ \alpha_{31} & \alpha_{32} & \alpha_{33} \end{bmatrix} \begin{bmatrix} AM_{t-1} \\ AW_{t-1} \\ V_{t-1} \end{bmatrix} + \begin{bmatrix} \epsilon_{1t} \\ \epsilon_{2t} \\ \epsilon_{3t} \end{bmatrix}$$

où **AM** est le nombre de clients acquis par les actions marketing de l'entreprise, **AW** est le nombre de clients acquis par le bouche à oreille, et **V** est la performance de l'entreprise.

3. On peut ensuite dériver les fonctions de réponse à l'impulsion pour évaluer l'impact d'un choc sur une des variables du système. Par exemple, Villanueva, Julian, Shijin Yoo, et Dominique M. Hanssens (2006) ont montré que les acquisitions de clients induites par le marketing sont plus rentables à court terme, tandis que les acquisitions par le bouche à oreille génèrent des performances plus lentement mais deviennent finalement deux fois plus rentables pour l'entreprise.

Ce type de modèle offre une vision dynamique de la CLV en considérant les interactions entre les différentes composantes.

Les modèles de diffusion/croissance

La prévision de l'acquisition de futurs clients est généralement réalisée de deux manières. La première approche utilise des données clients désagrégées et construit des modèles qui prédisent la probabilité d'acquérir un client particulier.

Une approche alternative consiste à utiliser des données agrégées et des modèles de diffusion ou de croissance pour prédire le nombre de clients qu'une entreprise est susceptible d'acquérir à l'avenir. Certes, cela ne traite pas directement de la valorisation du client mais ces modèles sont connexes à cette problématique. Les modèles de diffusion/croissance sont des outils utilisés pour prévoir l'adoption et la diffusion de nouveaux produits, technologies ou services au sein d'une population.

Il existe notamment le modèle de Bass (Vijay Mahajan, Eitan Muller, et Frank M. Bass (1990)), noté

$$n(t) = p \cdot (m - N(t)) + q \cdot \frac{N(t)}{m} \cdot (m - N(t))$$

Où :

- $n(t)$: nombre de nouveaux acheteurs du produit ou service considéré à l'année t
- $N(t)$ nombre cumulé d'acheteurs jusqu'à l'année t .
- m est le potentiel du marché, c'est-à-dire le nombre total d'acheteurs potentiel du produit à terme supposé fixe depuis le lancement.
- p est le coefficient d'innovation ou de l'influence externe, caractérisant la probabilité que quelqu'un qui n'utilise pas encore le produit se mette à l'utiliser à cause d'une influence externe au processus de diffusion: publicité, prix, notoriété du produit dans les médias,...
- q est le coefficient d'imitation ou de l'influence interne, caractérisant la probabilité que quelqu'un qui n'utilise pas encore le produit se mette à l'utiliser à cause de l'influence de ceux qui utilisent déjà le produit et du « bouche à oreille ».

Quand q est supérieur à p , les ventes de l'innovation augmentent au cours du temps, atteignent un maximum et diminuent. Quand q est inférieur à p , les ventes diminuent de façon monotone à partir de $t = 0$: il n'y a pas de diffusion.

Nous pouvons ensuite intégrer ces modèles de diffusion/croissance dans des modèles de CLV pour prédire la valeur des clients acquis à l'avenir. Par exemple, on peut utiliser cette prédiction pour modéliser la CE ainsi :

$$CE = \int_{k=0}^{\infty} \int_{t=k}^{\infty} n_k m_{t-k} e^{-ik} e^{-\left(\frac{1+i-r}{r}\right)(t-k)} dt dk - \int_{k=0}^{\infty} n_k c_k e^{-ik} dk$$

où n_k est le nombre de nouveaux clients acquis pour la cohorte k , m est la marge, r est le taux de rétention, i est le taux d'actualisation, et c est le coût d'acquisition par client.

On peut utiliser cette estimation de la CE afin d'estimer la valeur du portefeuille d'une entreprise. D'ailleurs Gupta S., Donald R. Lehmann et Jennifer Ames Stuart (2004) ont montré que l'équité client (CE) estime bien la valeur de marché des entreprises, sauf pour Amazon et eBay. Ils ont observé qu'une augmentation de 1 % du taux de rétention accroît la CE de presque 5 %, tandis qu'un changement similaire du taux d'actualisation ne l'augmente que de 0,9 %. Rust, Roland T., Tim Ambler, Gregory Carpenter, V. Kumar, et Rajendra Srivastava (2004) ont estimé la CE d'American Airlines à 7,3 milliards de dollars, proche de sa capitalisation de 1999. Ils ont également trouvé que des améliorations modestes de la qualité ou de la notoriété publicitaire peuvent augmenter significativement la CE. Hogan, John E., Katherine N. Lemon, et Barak Libai (2003) ont souligné les coûts indirects élevés de la perte d'un client, notamment en termes de bouche-à-oreille, surtout dans la banque en ligne.

Modèles Acquisition, de Rétention et Expansion

L'approche que nous avons choisie d'exploiter lors de notre future étude utilise les modèles ARE. Ils sont essentiels pour analyser le cycle de vie des clients et permettent de comprendre comment les clients sont acquis, retenus et comment leurs dépenses peuvent être augmentées au fil du temps (via le cross-selling et l'up-selling).

Ces modèles montrent que la rétention des clients existants est souvent plus rentable que l'acquisition de nouveaux clients, mais ils soulignent également que tous les clients fidèles ne sont pas nécessairement rentables. L'optimisation des coûts d'acquisition, combinée à une gestion active de la rétention et des ventes additionnelles, est un levier puissant pour optimiser la valeur de son portefeuille.

Customer Acquisition

L'acquisition dans notre cas se réfère comme le premier achat qu'un nouveau client effectue, ou ancien dans le cadre de l'effet "always a share".

Les modèles logit et probit sont les plus couramment utilisés pour modéliser l'acquisition (Gensch 1984; Thomas 2001), où la probabilité d'acquisition d'un client dépend de variables explicatives spécifiques au consommateur et de paramètres d'erreur (Lewis (2005)).

$$P(\text{Acquisition}_{jt} = 1) = P(\alpha_j \cdot X_{jt} + \epsilon_{jt} > 0)$$

où :

- Acquisition_{jt} est une variable binaire indiquant si le client j a acquis un produit ou un service à la période t ,
- X_j est un vecteur de variables explicatives,
- β est un vecteur de coefficients,

- ϵ_{jt} est un terme résiduelle.

Ce modèle cherche à estimer la probabilité qu'un client potentiel j acquière un produit ou un service à la période t , en fonction de ses caractéristiques et des variables explicatives.

Cependant, l'utilisation de ce précédent modèle nécessite la prise en compte du contexte de l'estimation de la valeur du portefeuille de l'entreprise. En effet, nous devons prendre en compte la différence entre une relation contractuelle ou non-contractuelle entre le client et l'entreprise. En effet, dans un cadre non-contractuelle, il se pourrait que nous n'ayons besoin de ne modéliser que la probabilité de premier achat du client étant donné que le contrat impliquerait que le client générerait des revenus similaires à chaque période. Or, dans une relation non-contractuelle, le comportement du client est incertain à chaque période, il nous faudrait donc modéliser la probabilité d'achat du client à chaque période.

De plus de nombreux facteurs sont en mesure d'influencer cette probabilité d'achat au-delà des caractéristiques propres du client. Est-ce que je me trouve sur un marché fortement concurrentiel ? Est-ce que mon bien peut bénéficier d'effets de réseau (c'est-à-dire si les clients obtiendront plus de satisfaction si mon produit est utilisé par d'autres personnes) ? Est-ce que l'engagement de dépenses publicitaires pourrait augmenter la probabilité d'achat ? Toutes ces questions sont à prendre en compte dans la modélisation de l'acquisition.

Enfin, il faut noter que l'acquisition d'un client implique des coûts plus ou moins élevés en fonction du contexte de son acquisition. Par exemple, l'acquisition d'un client grâce à un effet bouche à oreille n'a rien coûté en absolu tandis que l'acquisition de celui-ci par l'intermédiaire d'une notre stratégie publicitaire est coûteuse. Cependant, il est difficile de modéliser ces coûts pour chacun de nos clients.

Customer Retention

Après avoir discuté de l'acquisition, il convient maintenant de se demander comment modéliser le fait qu'un client puisse partir à un temps donné t , c'est au travers du calcul de la probabilité de rétention que l'on peut mesurer le comportement d'un client dans le temps afin de déterminer si celui-ci restera actif ou non.

La rétention client représente la probabilité qu'un client reste "actif" ou continue d'acheter auprès d'une entreprise. En contexte contractuel (comme les abonnements téléphoniques ou magazines), l'entreprise est informée de la fin de la relation par le client. Dans un contexte non-contractuel (comme l'achat de livres chez Amazon), l'entreprise doit inférer l'activité d'un client à partir de son comportement d'achat passé. Par exemple, eBay considère un client actif s'il a effectué une activité sur le site au cours des 12 derniers mois.

Quatre des concepts précédemment présentés sont à prendre en compte dans l'estimation de la probabilité de rétention :

- Les cadres **contractuel** et **non-contractuel**. En effet si nous nous plaçons dans un contexte de relation contractuel, par exemple une assurance habitation, étant

donné que le client est engagé légalement à l'entreprise il devient plus facile de modéliser cette rétention à l'inverse dans une relation non-contractuelle, par exemple avec un supermarché, il est bien plus difficile de modéliser cette rétention, l'entreprise doit inférer, au travers des achats passé par exemple, si le client est actif.

- Les approches opposées "perdu à jamais" et "toujours une part". La première approche considère que la défection d'un client est permanente et utilise souvent des modèles de durée (hazard models), comme les modèles de durée accélérée (AFT) ou les modèles à risques proportionnels (PH), pour prédire la probabilité de départ. Nous présenterons les notions utilisées par cette approche en [annexe](#).

La seconde approche suppose que le changement d'un client vers un concurrent est temporaire ("toujours une part de marché") et utilise généralement des modèles de migration ou de Markov. Ces modèles estiment les probabilités de transition entre différents états d'achat pour calculer la CLV.

L'approche "lost for good"

Le risque de défection peut être modélisé de différentes manières, en fonction des données disponibles et des hypothèses sur le comportement des clients. Par exemple, si l'on suppose que le risque de défection est constant dans le temps, le modèle de Cox est souvent utilisé et on le modélise ainsi:

$$h(t|X) = h_0(t) \exp(X\beta)$$

où $h(t|X)$ est le risque de défection à l'instant t pour un client avec des caractéristiques X , $h_0(t)$ est le risque de base, et β est le vecteur de coefficients.

En revanche, si l'on suppose que le risque de défection varie en fonction du temps, des modèles de durée accélérée (AFT) peuvent être plus appropriés.

$$S(t; X) = \psi \frac{(\log(t) - X\beta)}{\sigma}$$

où ψ est une distribution de survie standardisée, σ est le paramètre d'échelle, et β est le vecteur de coefficients.

Ainsi, on estime la probabilité qu'un client reste actif ou quitte l'entreprise en fonction de ses caractéristiques et du temps écoulé (probabilité de rétention) dont nous avons besoin pour calculer la CLV.

L'approche "lost for good" (perdu pour toujours) suppose que les clients perdus ne reviendront jamais et elle est souvent critiquée pour cette raison, tandis que l'approche "always a share of wallet" (toujours une part de marché) considère que les clients partis reviendront à un moment donné. Ces deux approches ont des implications différentes pour la CLV, car elles supposent des comportements de défection très différents.

Les modèles de Machine Learning

L'apprentissage automatique a généré de nombreuses approches mettant l'accent sur la capacité prédictive, comme les modèles de poursuite de projection, les réseaux de neurones, les arbres de décision, les splines de régression adaptative multivariée (MARS), les arbres de classification et de régression (CART), et les machines à vecteurs de support (SVM).

Ces approches sont particulièrement adaptées à l'étude de l'attrition des clients, où un grand nombre de variables pose le problème de la "malédiction de la dimensionnalité". Pour surmonter ces difficultés, Hastie, T. J. et R. J. Tibshirani (1990) ont proposé des modèles additifs généralisés, et Friedman, J. H. (1991) a développé MARS, une procédure de régression non paramétrique. Plus récemment, les SVM ont été utilisés pour la classification, démontrant une meilleure performance que les modèles logit dans des études comme celle de Giuffrida, Giovanni, Wesley Chu, et Dominique Hanssens (2000).

Concernant les arbres de décision une méthode intéressante repose sur des forêts aléatoires adapté au calcul de probabilité d'événements, le schéma ci-joint illustre le fonctionnement de cette méthode :




Figure 2 – Random Survival Forest

Source: ResearchGate

où le critère de séparation à chaque noeud, représenté par un point rouge, est basé sur un test du log-rank, chaque feuille terminale représente une estimation de la fonction de survie, et les prédictions sont obtenues en faisant la moyenne des estimations de chaque arbre.

Modèle de Markov

La seconde classe suppose que le changement d'un client vers un concurrent est temporaire ("toujours une part de marché") et utilise généralement des modèles de migration ou de Markov. Ces modèles estiment les probabilités de transition entre différents états d'achat pour calculer la CLV.

Le modèle de Markov est particulièrement utile pour modéliser les transitions des clients entre différents états (actif, dormant, churn). Il repose sur une matrice de transition qui décrit la probabilité qu'un client passe d'un état à un autre.

Soit P la matrice de transition où P_{ij} représente la probabilité qu'un client passe de l'état i à l'état j . Par exemple, avec trois états : S_1 (actif), S_2 (dormant), et S_3 (churn), la matrice de transition pourrait être :

$$P = \begin{bmatrix} P_{11} & P_{12} & P_{13} \\ P_{21} & P_{22} & P_{23} \\ P_{31} & P_{32} & P_{33} \end{bmatrix}$$

La probabilité d'être dans un certain état au temps $t + 1$, notée π_{t+1} , est obtenue par multiplication de la distribution actuelle des états (π_t) avec la matrice de transition P :

$$\pi_{t+1} = \pi_t \cdot P$$

Cela permet de prévoir la probabilité qu'un client soit actif, dormant ou ait quitté l'entreprise à une période future, en fonction de son état actuel. Les modèles de Markov sont particulièrement utiles pour prédire le comportement des clients dans des contextes où les transitions entre états sont fréquentes et où les clients peuvent revenir à un état antérieur.

Une fois que l'on a établi la matrice de transition, on peut calculer la CLV en utilisant la formule suivante :

$$V' = \sum_{t=0}^T ((1+i)^{-1}P)^t \cdot R$$

où V est le vecteur des CLV attendues pour chaque état, P est la matrice de transition, R est le vecteur des revenus futurs attendus, i est le taux d'actualisation, et T est l'horizon temporel défini par l'entreprise.

La recherche sur la rétention a également montré l'importance de la satisfaction client, de la qualité produit, et des contacts réguliers pour maximiser la fidélité. Reichheld et W. Earl Sasser Jr. (1990) ont estimé qu'une augmentation de 5 % de la rétention client pourrait accroître la rentabilité de 25 % à 85 %, mais d'autres recherches, comme celles de Reinartz, Werner et V. Kumar (2002), ont mis en évidence une corrélation faible à modérée entre la durée de relation et la rentabilité, suggérant que d'autres facteurs influencent la CLV.

Customer Margin and Expansion

La marge client est un indicateur clé pour évaluer la rentabilité des clients. Elle est définie comme la différence entre les revenus générés par un client et les coûts associés à ce client. Les coûts peuvent être divisés en coûts d'acquisition, coûts de service, et coûts de rétention. La marge client est souvent utilisée pour segmenter les clients en fonction de leur rentabilité, en identifiant les clients les plus rentables et ceux qui nécessitent des efforts supplémentaires pour augmenter leur valeur.

L'expansion client consiste à augmenter la valeur des clients existants en leur vendant des produits ou services supplémentaires. Les stratégies d'expansion incluent le cross-selling (vente de produits complémentaires) et l'up-selling (vente de produits plus chers ou de plus hautes gamme). Ces stratégies sont souvent utilisées pour augmenter la CLV en maximisant les revenus générés par chaque client.

Cette composante suggère une fois de plus des différences notables entre l'estimation de la CLV dans un cadre contractuel ou non-contractuel. En effet, la première approche supposerait des revenus potentiels similaire à chaque période rendant l'estimation de l'impact de cette composante relativement simple par rapport à la seconde approche où il serait nécessaire d'estimer la probabilité de participation (d'achat) du client à chaque période en plus de devoir mettre en place un modèle de comptage pour déterminer l'intensité de sa participation (ou plus simplement son nombre d'achat). Enfin, Il serait tout à fait envisageable de considérer des modèles auto régressifs type ARMA et ses multiples extensions afin de déterminer les achats futurs d'un client en fonction de ses caractéristiques.

$$R_{t+1} = \beta_0 + \beta_1 R_t + \beta_2 R_{t-1} + \dots + \beta_n R_{t-n} + \epsilon_{t+1}$$

Le tableau suivant récapitule les différentes études et les différents modèles de valorisation client jusqu'en 2014 :

Table 1 – Tableau récapitulatif des modèles de valorisation client

Tableau récapitulatif des modèles de valorisation client		
Auteurs	Années de publication	Éléments définissant le modèle
Berger and Nasr	1998	diagnosing Net contribution margin
Carpenter	1995	quantify the relationship between a company and its users
Blattberg and Deighton	1996	identify acquisition and retention cost
Wang, P. and Spiegel, T.	1994	dynamic interaction of acquisition and retention cost
Pfeifer and Carraway	2000	Markov chain model
Rust	2000	Markov chain model to incorporate brand switching metrics
Blattberg	2001	return on acquisition, return on retention and return on add-on selling
Gupta and Lehmann	2003	Infinite projection period
Hwang, Jung, Suh	2003	current value, potential value and customer loyalty
Liu, Zhao, Zhang and Lu	2004	Word-of-mouth
Venkatesan and Kumar	2004	Consider resource allocation
Junxiang Lu and Overland Park	2005	survival analysis
Fader, Hardie, Lee		RFM
Colombo and Jiang	1999	stochastic RFM
Liu and Shih	2005	WRFM
Hughes	2005	RFM
Hwang, Jung, Suh, Kim	2006	customer defection and cross-selling opportunities
Crowder, Hand and Krzanowski	2007	expected income, customer-specific effect
Haenlein, Kaplan and Beeser	2007	Markov chain model
I-Cheng Yeh, King-Jang Yang, Tao-Ming Ting	2009	RFMTC model
Cheng, Chiu and Wu	2011	Markov chain model
Ahmadi, Taherdoost, Fakhravar and Jalaliyoon	2011	Market risk, flexibility of firm, cost of customer attraction/retention

Source : M. EsmaeiliGookeh & M. J. Tarokh, 2013, Customer Lifetime Value Models: A Literature Survey

Présentation de notre étude

Base de Données : Telco

Au cours de notre prochaine étude, nous allons tenter de mettre en place un modèle estimant la valeur des clients d'une entreprise de télécommunication. Pour cela, nous disposons de la base de données **Telco** mise à disposition par **IBM**. Telco est un ensemble de données largement utilisé dans les projets d'analyse et de modélisation prédictive, en particulier pour des études axées sur la fidélisation des clients. Elle contient des informations provenant d'une entreprise de télécommunications regroupant des données client, contractuelles et financières. Son objectif principal est de fournir un ensemble riche et diversifié de caractéristiques permettant d'identifier les facteurs influençant la rétention ou la résiliation des clients. La base contient plus de **7000 observations**, chacune représentant un client, et regroupe une vingtaine de variables initialement.

Elle contient des informations sur les catégories de variables suivantes :

1. Informations sur les clients

- *CustomerID* : Identifiant unique du client.
- *Démographie* : Sexe, tranche d'âge, statut marital, nombre de d'individus dépendants au foyer, etc.

2. Informations contractuelles

- *Type de contrat* : Mensuel, annuel ou biannuel.
- *Type d'offre* : Indique l'offre auquel le client a souscrit, elles sont au nombre de 5.
- *Mode de paiement* : Paiement automatique, carte de crédit, virement bancaire ou par chèque.
- *Durée d'engagement* : Nombre de mois passés chez le fournisseur.

3. Utilisation des services

- Services inclus :
 - *Téléphone* : Ligne unique ou plusieurs lignes.
 - *Internet* : Type de connexion (DSL, fibre optique, aucune).
 - *Services supplémentaires* : Sécurité internet, sauvegarde en ligne, streaming TV, streaming de films.

4. Données financières

- *Montant mensuel* : Facture mensuelle moyenne.
- *Charges totales* : Montant total payé depuis le début du contrat.

5. Indicateur de churn

- *Churn* : Variable binaire indiquant si le client a résilié son contrat ou non.

i IBM (International Business Machines Corporation)

Fondée en 1911 et basée à Armonk, New York, IBM est une entreprise technologique de renommée mondiale. Elle est pionnière dans les domaines du cloud computing, de l'intelligence artificielle (IA) avec Watson, du matériel informatique et des solutions logicielles d'entreprise. IBM est connue pour ses innovations majeures comme le mainframe, l'ordinateur quantique et les technologies blockchain. Avec une présence dans plus de 170 pays, elle continue d'influencer l'évolution du numérique et des technologies d'entreprise.

Méthodologie

Nous chercherons à estimer la **CLV** dans un cadre **contractuel**, en exploitant les données disponibles. Notre approche repose sur la modélisation de la durée de vie des clients à l'aide d'une fonction de survie, permettant d'évaluer leur probabilité de rétention à chaque période. Toutefois, nos méthodes ne sont pas directement transposables à un cadre non contractuel, où la relation client-entreprise est plus informelle et moins structurée. De plus, nos données actuelles ne permettent pas d'analyser l'impact de la concurrence sur la CLV, ce qui constitue une limitation importante de notre étude.

Notre étude ne s'articulera pas autour de 3 mais de seulement 2 dimensions à savoir la rétention et la génération de revenus, en effet notre jeu de données étant limité aux clients déjà acquis, nous ne sommes pas en mesure d'analyser directement les facteurs influençant la probabilité de signature d'un contrat à chaque période.

L'analyse de la rétention client sera réalisée à travers une approche fondée sur l'**analyse de survie**. Une contrainte majeure réside dans la disponibilité temporelle des variables explicatives. Par exemple, certaines variables comme le score de satisfaction ne sont accessibles qu'après un sondage, ce qui nous oblige à contextualiser nos estimations selon le moment de l'évaluation : avant ou après la signature du contrat, avant ou après la collecte d'informations supplémentaires. De plus, nous posons l'hypothèse simplificatrice qu'un client ayant résilié son contrat ne reviendra jamais, ce qui exclut l'utilisation de modèles de migration ou de Markov.

En ce qui concerne la marge potentielle réalisée sur chaque client, nous disposons d'informations sur les revenus générés ainsi que sur les services souscrits, mais nous ne possédons pas de données détaillées sur les coûts associés à ces services. Cette contrainte nous empêche d'estimer directement la rentabilité individuelle des clients. Nous avons donc dû réajuster notre objectif initial. Plutôt que d'estimer une CLV basée sur la rentabilité, nous chercherons à estimer la valeur actuelle des revenus bruts générés par un client sur les 36 prochains mois. Cette estimation se fera selon la formule suivante

$$CLV_i = \sum_{t=1}^T \frac{Monthly\ Charge_i * \hat{P}(T_{it} > t)}{(1 + d)^t}$$

avec :

- i : individu
- T : notre horizon temporel
- d : le taux d'actualisation
- $Monthly\ Charge_i$: La somme mensuel payée par le client i
- $P(T_{it} > t)$: La probabilité de survie de l'individu i au temps t .

Nos résultats seront comparés à une valeur empirique calculée selon la formule suivante :

$$CLV_i = \min\{\text{nombre de mois de relation}_i ; 36\} * \text{Monthly Charge}_i$$

Pour tenir compte de l'incertitude inhérente à notre modélisation, nous adopterons une approche par scénarios, en distinguant trois cas :

- Un scénario **pessimiste**, où nous considérons des probabilités de survie plus faibles en utilisant la borne inférieure de l'intervalle de confiance de la fonction de survie estimée pour chaque individu ;
- Un scénario **central**, basé sur les prévisions moyennes du modèle, où les fonctions de survie sont estimées à partir des coefficients des effets des covariables ;
- Un scénario **optimiste**, où nous maximisons la valeur client en prenant la borne supérieure de l'intervalle de confiance de la fonction de survie estimée.

Par ailleurs, nos modèles d'estimation varieront en fonction des informations disponibles et du moment de l'évaluation. Par exemple, la valeur d'un client existant pourra être estimée en exploitant des variables comme le score de satisfaction, tandis que pour un client potentiel, ces données ne seront pas accessibles, nécessitant une approche différente. Pour la suite de l'étude, nous nommerons ces situations **des contextes**.

Notre objectif étant d'estimer une valeur actuelle nette, il est essentiel de définir un **horizon temporel** ainsi qu'un **taux d'actualisation** pour valoriser les profits futurs. Dans ce cadre, notre estimation portera sur les **36 prochains mois**, avec un taux d'actualisation mensuel fixé à **0.417 %** (5/12 %).

Enfin, pour évaluer la robustesse de notre estimation, cette comparaison sera effectuée sur un échantillon représentatif de clients, sélectionnés en fonction de leurs comportements de résiliation :

- Clients ayant résilié tôt,
- Clients ayant maintenu leur abonnement sur une période intermédiaire,
- Clients toujours actifs.

Pour répondre à ces différentes problématiques, nous avons adopté un plan en quatre parties. Les trois premières parties auront pour objectif d'étudier séparément chaque contexte, en tenant compte de leurs contraintes spécifiques et en fournissant une estimation de la valeur client adaptée au contexte d'évaluation. La quatrième partie viendra à comparer les résultats obtenus et à analyser les différences entre les modèles. Cette comparaison nous permettra également d'évaluer l'apport de chaque approche et d'identifier l'importance de certaines variables dans l'estimation de la valeur client.



 À retenir pour la suite

- Cadre contractuel
- Approche “Perdu pour toujours”
- Estimation de la CLV sur 36 mois
- 3 Scénarios :
 - Pessimiste
 - Central
 - Optimiste
- 3 Contextes :
 - Avant la signature d’un contrat
 - Après la signature d’un contrat
 - Après l’enquête de sondage sur les clients

Analyse descriptive

Avant de plonger dans la modélisation, il est essentiel de comprendre les caractéristiques de notre base de données. Cette étape nous permettra de mieux appréhender les relations entre les variables et d'identifier les éventuelles corrélations.

La répartition du Churn se fait comme ceci :




Ainsi approximativement **70 %** des clients sont toujours actifs, tandis que **30 %** ont résilié leur contrat.

De manière assez logique, on observe une propension au churn plus élevée sur les courtes périodes que sur les longues périodes. Cela pourrait indiquer que les clients qui restent moins longtemps ont plus de chances de se désabonner rapidement, tandis que ceux qui restent plus longtemps ont peut-être trouvé une certaine valeur ou satisfaction dans le service, ce qui les rend moins enclins à partir.

Etude des variables catégorielles


Notre base de données contient un grand nombre de variables catégorielles utilisables dans le cadre de notre étude, étudions leurs caractéristiques avant de les utiliser

Observons dans un premier temps la répartition des clients en fonction de leur type de contrat ainsi que leurs courbes de survie :




Nous voyons que la majorité des clients ont un contrat mensuel

Une autre variable qui nous a paru importante dès le début est **Offer**, représentant 5 offres différentes que l'entreprise propose (6 si nous partons du principe que ne pas avoir d'offres est une offre en soit), en effet il est logique de penser que le type d'offre choisi va influencer la durée de vie du client ou/et ce qu'il paye et donc in fine influencer la valeur de ce client pour l'entreprise.



On voit que la majorité des clients n'ont pas choisi d'offre particulière.

Les deux graphiques ci dessous permettent de visualiser la répartition de la durée de vie moyenne et du revenu total moyen en fonction du type de contrat et de l'offre choisie.



Ainsi on voit que les clients ayant choisi l'offre A ont une durée de vie moyenne bien supérieur aux autres offres et ce peu importe le type contrat et fournisse le revenu moyen le plus élevé sur le contrat mensuel.

À l'inverse, les clients ayant opté pour l'offre E ont une durée de vie moyenne nettement inférieure à celles des autres offres et génèrent le revenu moyen le plus faible, quel que soit le type de contrat.

Modélisation économétrique

Introduction

Dans cette analyse, nous étudierons les trois contextes avec une démarche similaire.

Dans un premier temps, nous définirons les variables pertinentes et déterminerons le modèle le plus approprié pour estimer les probabilités de survie à chaque mensualité à l'aide d'un modèle **AFT** (**annexe**). Il est essentiel de limiter le nombre de variables intégrées dans le modèle afin d'éviter le risque de surapprentissage, qui pourrait conduire à capturer du bruit plutôt que de véritables relations statistiques. L'objectif est donc d'identifier un ensemble optimal de variables explicatives.

Après avoir ajusté le modèle sur l'échantillon d'entraînement, nous observerons ses prédictions sur un échantillon test en estimant la valeur client. Cette validation sur un échantillon indépendant nous permettra d'apprécier la capacité généralisatrice du modèle et d'assurer sa pertinence en dehors des données initiales. Enfin, nous chercherons à estimer la valeur du portefeuille de l'entreprise en sommant les **CLV** de chaque client.

Sélection du modèle

Quelles sont les variables à sélectionner ?

En économétrie appliquée, il existe une multitude de méthodes permettant de sélectionner un sous-ensemble optimal de variables explicatives pour un modèle. Dans cette étude, nous avons choisi de nous concentrer sur la **Stepwise Selection**.

La Stepwise Selection adopte une approche **déterministe**, où la sélection des variables est guidée par un critère précis, tel que les critères d'information comme l'**Akaike Information Criterion** (AIC) ou le **Bayesian Information Criterion** (BIC). Ce processus itératif consiste à ajouter ou supprimer des variables dans le modèle en fonction de leur significativité statistique, et ce, dans une séquence rigide. La méthode suit une série d'étapes déterminées par les critères choisis et se base sur les résultats des tests statistiques pour décider des variables à conserver ou à éliminer. Cette approche, bien que simple et rapide, peut parfois être limitée par son incapacité à explorer de manière exhaustive les interactions complexes entre les variables ou à échapper à des solutions sous-optimales dues à l'ordre dans lequel les variables sont introduites ou éliminées.

 Algorithme Stepwise Selection (Both) avec AIC**Initialisation**

1. Commencer avec un modèle initial (vide ou contenant des variables pertinentes).
2. Calculer le critère d'information d'Akaike (AIC) du modèle actuel.

Sélection avant (Forward Selection)

1. Tester l'ajout de chaque variable candidate une par une.
2. Estimer le modèle avec chaque nouvelle variable ajoutée.
3. Calculer l'AIC pour chaque modèle testé.
4. Ajouter la variable qui réduit le plus l'AIC, si une amélioration est constatée.

Élimination arrière (Backward Elimination)

1. Tester la suppression de chaque variable actuellement dans le modèle.
2. Estimer le modèle sans chaque variable candidate à supprimer.
3. Calculer l'AIC pour chaque modèle testé.
4. Supprimer la variable dont le retrait réduit le plus l'AIC, si une amélioration est constatée.

Vérification de convergence}

1. Répéter les étapes de **Forward Selection** et **Backward Elimination** jusqu'à ce qu'aucune modification (ajout ou suppression) ne réduise davantage l'AIC.

Résultat

- Le modèle final est celui avec l'AIC le plus bas après toutes les itérations.

 Stepwise Selection**Avantages :**

- Méthode simple et facile à implémenter.
- Permet de réduire la complexité du modèle en éliminant les variables non significatives.

Limites :

- Sensible à l'ordre des variables dans le modèle initial.
- Ne prend pas toujours en compte les interactions complexes entre les variables.

Quelles sont les distributions à sélectionner ?

Dans le cadre des modèles de type AFT, le choix de la distribution pour modéliser le temps de survie joue un rôle crucial. En effet, il influence directement l'estimation des paramètres et la qualité des prédictions. Une liste non exhaustive des distributions possibles est présentée en [annexe](#).

Pour tester nos modèles, nous avons utilisé les packages `survival` et `flexsurv` de R, qui nous ont permis d'explorer un total de six distributions. Parmi celles-ci, on retrouve les suivantes :

- Exponentielle
- Weibull
- Log-normale
- Log-logistique
- Gamma généralisée
- Fisher généralisée

Ces distributions offrent une grande flexibilité pour s'adapter à diverses formes de données de survie et permettent de mieux comprendre le comportement des risques au fil du temps.

Quels critères de sélection ?

Pour sélectionner le modèle final, nous avons comparé les modèles générés par ces deux approches en utilisant une gamme de critères d'évaluation. Parmi ceux-ci, nous avons pris en compte des indicateurs classiques tels que l'AIC et le BIC. De plus, nous avons intégré des critères spécifiques aux modèles d'analyse de survie, tels que la concordance et le Brier score, afin d'évaluer la performance de manière plus ciblée et adaptée à notre contexte.

- **AIC et BIC :**

L'AIC est un critère largement utilisé pour évaluer la qualité d'un modèle en prenant en compte à la fois la qualité de l'ajustement et la complexité du modèle. Il pénalise les modèles avec un grand nombre de paramètres pour éviter le surajustement. L'avantage de l'AIC réside dans sa simplicité et son efficacité pour comparer des modèles avec des structures différentes. Cependant, son inconvénient principal est qu'il n'est pas toujours optimal lorsque les modèles sont très différents en termes de distribution ou de données.

Le BIC est similaire à l'AIC mais avec une pénalité plus forte pour les modèles complexes, car il inclut un facteur qui dépend de la taille de l'échantillon. Son principal avantage est qu'il tend à sélectionner des modèles plus simples et moins sujets au surajustement, surtout pour des échantillons de grande taille. Cependant, il peut être trop conservateur et éliminer des modèles qui sont statistiquement significatifs mais qui comportent un nombre plus élevé de paramètres.

$$\text{AIC} = -2 \ln(\hat{L}) + 2k \quad ; \quad \text{BIC} = -2 \ln(\hat{L}) + k \ln(n)$$

Où :

- $\hat{L}$ est la log-vraisemblance du modèle,
- k est le nombre de paramètres du modèle,
- n est le nombre de clients.

- **Concordance :**

La concordance est un critère utilisé principalement pour évaluer les modèles de survie. Elle mesure la capacité du modèle à prédire correctement l'ordre des événements (par exemple, l'ordonnancement des clients selon leurs temps de survie).

 Limites

- La concordance n'est pas un critère permettant de juger la précision des prédictions d'un modèle
- Elle peut être moins informative si les événements sont rares ou si les données sont déséquilibrées

- **Brier Score :**

Le Brier score (Glenn W. Brier, 1950) mesure l'erreur quadratique moyenne entre les probabilités prédites et les résultats observés, et il est particulièrement adapté aux modèles de survie où les résultats sont souvent des probabilités. L'avantage du Brier score est qu'il prend en compte à la fois la précision des prévisions et leur calibration.

$$BS = \frac{1}{N} \sum_{i=1}^N \hat{W}_i(t) \cdot (\delta_i(t) - \hat{S}(t))^2 \quad ; \quad \hat{W}_i(t) = \frac{(1 - \delta_i(t))\Delta_i}{\hat{G}(T_i)} + \frac{\delta_i(t)}{\hat{G}(t)}$$

- $\hat{W}_i(t)$: Sert de pondération des individus selon qu'il soit censuré ou non
- $\delta_i(t)$: Indicateur d'événement :
 - Il vaut 1 si l'individu i a connu l'événement (ex : résiliation) avant ou en t .
 - Il vaut 0 si l'individu n'a pas toujours pas résilié en t .
- $\hat{S}(t)$: Probabilité de survie prédite par le modèle au temps t
- Δ_i : Indicateur de censure :
 - Il vaut 1 si l'individu i a résilié durant la période de temps.
 - Il vaut 0 si l'individu i est censuré (perdu de vue avant l'événement).
- $\hat{G}_i(T_i)$: Probabilité de censure au temps t
 - Il estime la probabilité qu'un individu soit encore "suivi" au temps T_i , c'est-à-dire qu'il n'ait pas été perdu de vue avant.
 - Il est calculé via un estimateur de Kaplan-Meier appliqué aux temps de censure.

Cet indicateur nous semble particulièrement pertinent pour notre étude, car il évalue l'exactitude absolue des prédictions de notre modèle tout en pondérant leur pertinence. En effet, prédire le temps de survie d'un individu n'ayant jamais résilié apparaît peu significatif.

 Pour la suite

Nous utiliserons le Brier Score intégré sur l'ensemble des périodes de temps pour évaluer la précision moyenne du modèle sur toutes ses prédictions.

 Implémentation des packages

Le package `survMetrics` nous a permis de calculer la concordance (C-index) et le Brier Score intégré pour les distributions proposées par `survival`. En ce qui concerne les distributions disponibles dans `flexsurv`, nous avons dû adapter les fonctions **Cindex** et **IBS** de `survMetrics` pour pouvoir les utiliser avec ces nouvelles distributions. Cette adaptation a été nécessaire afin de garantir des évaluations cohérentes et précises des performances des modèles de survie, quel que soit le package utilisé.

De plus la calcul du Brier Score Intégré étant computationnellement coûteux, nous avons dû modifier légèrement le code source afin de paralléliser le calcul.

Hypothèses à vérifier

Après avoir construit un modèle économétrique basé sur un modèle AFT, plusieurs hypothèses doivent être vérifiées afin d'assurer la validité et la robustesse des résultats. Voici une liste complète des hypothèses à examiner :

1. Distribution des temps de survie : le modèle AFT suppose que les temps de survie suivent la distribution statistique définie. Pour vérifier cette hypothèse, nous testerons les différentes distributions et nous chercherons à définir celle qui permet d'obtenir de meilleurs scores (aux métriques définis).
2. Linéarité du temps de log : une hypothèse fondamentale du modèle AFT est que le logarithme du temps de survie est une fonction linéaire des covariables. Cette hypothèse de linéarité simplifie l'interprétation des coefficients du modèle, qui représentent l'effet du rapport temporel des covariables sur la durée de survie.
3. Indépendance des temps de survie : le modèle suppose que les temps de survie de différents individus sont indépendants les uns des autres. Au vu de ce que représente nos données, cette hypothèse est respectée.
4. Homoscédasticité : le modèle AFT suppose que la variance du terme d'erreur est constante d'une observation à l'autre. Cette hypothèse d'homoscédasticité garantit que le modèle fournit des estimations impartiales et efficaces des coefficients de régression.
5. Censure non informative : le modèle suppose que la censure n'est pas informative, ce qui signifie que la raison de la censure n'est pas liée au risque que l'événement se produise. La violation de cette hypothèse peut conduire à des estimations biaisées. Le fait que nous utilisions l'analyse de survie pour modéliser la rétention des clients implique que nous supposons que cette hypothèse est vérifiée.

Les risques sont-ils proportionnels ?

Tout d'abord, nous procéderons à un test de Log-Rank afin d'évaluer si l'impact de certaines variables sur la survie des individus est statistiquement significatif.

$\left\{ \begin{array}{l} H_0 : \text{Les courbes de survie sont identiques entre les groupes.} \\ H_1 : \text{Les courbes de survie sont différentes entre les groupes.} \end{array} \right.$

Table 2 – Résultats des tests du log-Rank

	$\chi^2_{statistic}$	p_{value}
Gender	0.5257	$4.68e - 01$
N_dependents	414.5476***	$9.60e - 91$
Partner	423.5431***	$4.13e - 94$
cat_age	46.9332***	$1.57e - 09$
Payment Method	865.2395***	$3.07e - 187$
Paperless Billing	189.5115***	$4.06e - 43$
Offer	2350.5716***	$0.00e + 00$
Service Internet	251.1972***	$1.42e - 56$
Service Téléphonique	0.4308	$5.12e - 01$
Unlimited Data	130.8373***	$2.69e - 30$
Referred a Friend	390.5639***	$6.24e - 87$

À présent, nous allons analyser les courbes log-log afin de vérifier si les risques sont proportionnels. Si tel est le cas, les courbes (représentant différentes modalités) doivent être séparées par un scalaire, et ce, indépendamment de la période de temps considérée.




Figure 3 – Les risques sont-ils proportionnels ?




Figure 4 – Les risques sont-ils proportionnels ?




Figure 5 – Les risques sont-ils proportionnels ?




Figure 6 – Les risques sont-ils proportionnels ?




Figure 7 – Les risques sont-ils proportionnels ?

Offer




Figure 8 – Les risques sont-ils proportionnels ?

Sur la base de l'analyse combinée des courbes $\log(-\log)$ de survie et des résultats du test du log-rank, nous pouvons conclure les éléments suivants :

- Les courbes de survie associées aux variables **Gender** et **Service Téléphonique** ne présentent pas de différence statistiquement significative, suggérant une absence d'effet notable de ces variables sur le taux de résiliation.
- Les courbes de survie des variables **Partner**, **Paperless Billing**, **Unlimited Data** et **Referred a Friend** apparaissent visuellement parallèles, ce qui pourrait indiquer le respect de l'hypothèse de proportionnalité des risques. Toutefois, l'évaluation à l'œil nu demeure insuffisante pour une validation formelle.
- En revanche, les courbes de survie des variables **Service Internet**, **Offer**, **N_dependents**, **cat_age** et **Payment Method** affichent des écarts non parallèles, invalidant ainsi l'hypothèse de proportionnalité des risques. Cela suggère que l'effet de ces variables sur le risque de churn évolue au fil du temps.

Résidus de Schoenfeld

Pour justifier le choix d'un modèle à temps de défaillance accéléré, nous nous appuyons également sur les résidus de Schoenfeld, qui permettent de rejeter l'hypothèse de proportionnalité des risques.

- $$\begin{cases} H_0 : \text{Les covariables n'ont pas d'interaction avec le temps.} \\ H_1 : \text{Les covariables ont une interaction avec le temps.} \end{cases}$$

Table 3 – Résultats du test des résidus de Schoenfeld

	$\chi^2_{statistic}$	df	p_{value}
factor(Gender)	0.3329	1	$5.64e - 01$
factor(Contract)	47.5934***	2	$4.63e - 11$
factor(Payment Method)	24.0652***	3	$2.42e - 05$
factor(Partner)	1.5214	1	$2.17e - 01$
factor(N_dependents)	25.8559***	2	$2.43e - 06$
factor(cat_age)	2.1706	4	$7.04e - 01$
factor(Paperless Billing)	2.281	1	$1.31e - 01$
factor(Offer)	651.7716***	5	$1.31e - 138$
Monthly Charges	62.3779***	1	$2.83e - 15$
factor(Service Internet)	30.2664***	1	$3.77e - 08$
factor(Service Téléphonique)	0.0516	1	$8.20e - 01$
axe3	53.8567***	1	$2.16e - 13$
factor(Unlimited Data)	2.9816*	1	$8.42e - 02$
factor(Referred a Friend)	0.9562	1	$3.28e - 01$
Satisfaction Score	96.7888***	1	$7.71e - 23$
Global	914.9075***	3e + 01	$3.85e - 176$

La majorité des p-values sont significatives, ce qui conduit à rejeter l'hypothèse de proportionnalité des risques. Par conséquent, un modèle à risques proportionnels semble inapproprié pour ces données. Nous prenons alors la décision d'utiliser des modèles à temps de défaillance accéléré.

💡 Modèle AFT

$$\ln(T) = X\beta + u$$

Distribution :

- Exponentielle : $u = w$ où W suit une loi de valeur extrême, avec une densité $f(w) = e^w \exp(-e^w)$.
- Weibull : $u = \alpha w$ où W suit une loi de valeur extrême, avec une densité $f(w) = e^w \exp(-e^w)$.
- Log-Logistique : $u = w$ avec $W \sim \mathcal{L}(\mu, \beta)$
- Log-Normale : $u = w$ avec $W \sim \mathcal{N}(0, \sigma^2)$
- Gamma Généralisée : voir [annexe](#)
- Fisher Généralisée : $u = w$ avec $W \sim \log(\mathcal{F}(v_1, v_2))$

Cas 1 : Etude pré-intégration

Dans ce premier contexte, l'entreprise de télécommunications dispose de très peu d'informations sur l'individu en question. En effet, celui-ci n'est actuellement pas encore client de l'entreprise, ce qui rend l'estimation de sa valeur potentielle particulièrement complexe. Toutefois, bien que cette tâche soit difficile, il est d'une importance stratégique pour Telco d'estimer cette valeur, car l'objectif principal de l'entreprise est de maximiser ses profits à long terme.

En effet, pour Telco, être capable de prévoir le potentiel de chaque client avant qu'il ne devienne un client actif peut avoir des conséquences sur sa stratégie commerciale. En ayant une estimation de la valeur potentielle d'un individu, l'entreprise peut déterminer si elle doit investir des ressources pour attirer ce client, ou si, au contraire, il serait plus judicieux de concentrer ses efforts sur d'autres prospects avec un potentiel de rentabilité plus élevé. Cela permettrait de prioriser les efforts de marketing et d'acquisition, ce qui serait un levier pour optimiser les coûts d'acquisition et maximiser le retour sur investissement.

Dans ce contexte, Telco pourrait envisager d'utiliser diverses variables disponibles pour estimer cette valeur, en tenant compte des comportements et caractéristiques observables qui pourraient influencer la probabilité qu'un individu devienne un client à long terme et génère une valeur à vie. Ces variables peuvent inclure des informations démographiques, géographiques, ou comportementales, bien que dans ce cas précis, les données disponibles soient limitées. Nous utiliserons les variables suivantes :

- **Gender** : Le genre de l'individu
- **Lat Long** ; **Latitude** ; **Longitude** ; **City** ; **Zip Code** : Relative à la localisation de l'individu ;
- **Partner** : Est-ce que l'individu vit avec un conjoint ?
- **Dependents** / **Number of Dependents** : Est-ce que l'individu vit avec une personne dépendante (enfants, personnes avec un handicap physique ou mental) ? / Combien ?
- **Senior Citizen** / **Under 30** : Est-ce que l'individu a plus de 60 ans / moins de 30 ans ?
- **Âge** / **cat_age** : L'âge de l'individu / Son appartenance à une catégorie d'âge

i Autres variables

- Nous considérerons les termes quadratiques des variables numériques que nous jugeons pertinents
- Nous considérerons aussi les effets d'interactions que nous jugeons pertinents (nous devons nous limiter à des interactions de degré 2 afin d'éviter un trop grand nombre de calculs)

⚠ Considération à prendre en compte

Il est certes difficile de savoir si une entreprise peut toujours détenir ces informations, mais elle peut les acquérir puisqu'elles existent dans ce contexte.

Cette première analyse reste toutefois très hypothétique, et il est probable que nos premières estimations de la valeur de ces clients potentiels s'écartent considérablement de la réalité.

Lors de la sélection des variables, la méthode `step_aic` a retenu les variables `Gender`, `cat_age`, `N_dependents`, ainsi que les effets d'interaction `Gender*Partner`, `Gender*N_dependents` et `Partner*N_dependents`, après avoir pris en compte l'intégralité des quatre variables et de leurs interactions.

Sélection de la distribution

Les graphiques ci-dessous présentent les courbes de survie et de risque prédites pour trois types d'individus : l'un ayant eu une relation de 10 mois avec l'entreprise, l'autre de 53 jours, et le dernier étant un individu censuré, dont la relation a duré 72 jours sans résiliation pendant la période d'étude. Nous avons également illustré la courbe de survie et de risque prédite pour l'individu moyen, ainsi que la courbe de survie estimée par l'estimateur de Kaplan-Meier, dont nous avons dérivé la courbe de risque.




Figure 9 – Cas 1 : Loi Exponentielle (PH et AFT)







Figure 10 – Cas 1 : Loi Weibull (AFT)


Les deux lois précédentes offrent un ajustement limité, bien qu'une amélioration notable soit observée entre la loi exponentielle et la loi de Weibull. En effet, le paramètre de forme de la loi de Weibull permet de modéliser une décroissance de la fonction de risque, tandis que la fonction de survie exponentielle présente une décroissance quasi-monotone en raison de son risque constant. Il semble peu probable que ce risque demeure constant au fil du temps. La loi de Weibull, quant à elle, permet de considérer que ce risque soit constant, soit croissant, soit décroissant, ce qui affecte la forme de la courbe de survie. Cependant, ces deux lois restent relativement simples et ne semblent pas suffisantes pour offrir une prédiction robuste.

**Figure 11** – Cas 1 : Loi Log-Logistique (AFT)**Figure 12** – Cas 1 : Loi Log-Normale (AFT)

Loi Gamma Généralisée

**Figure 13** – Cas 1 : Loi Gamma Généralisée (AFT)

Loi Fisher Généralisée

**Figure 14** – Cas 1 : Loi Fisher Généralisée (AFT)

En raison du manque d'informations disponibles dans ce contexte, même les modèles les plus complexes rencontrent des difficultés dans leurs prédictions. Cela se reflète notamment dans les fonctions de risque estimées. Il paraît peu probable qu'un individu ayant survécu 53 mois ait un risque de défaillance qui décroît strictement à partir du premier mois. Bien que l'on reconnaisse qu'il ne suffit pas d'examiner la prédiction d'un seul individu pour tirer des conclusions sur la performance du modèle, nous constaterons plus tard que ce comportement se généralise à un grand nombre d'individus.

⚠ Fausses indications

Il ne serait pas pertinent de fonder l'analyse de l'ajustement de nos modèles uniquement sur la comparaison de la courbe de survie prédite pour l'individu moyen avec celle de la courbe de survie Kaplan-Meier. En effet, cette approche omet plusieurs aspects importants. La courbe de survie Kaplan-Meier reflète l'estimation empirique de la fonction de survie en fonction des données observées pour tous les individus, sans supposer un modèle particulier. Par contre, l'ajustement des modèles paramétriques ou semi-paramétriques repose sur des hypothèses concernant la forme de la fonction de survie et du risque, ce qui peut induire des différences non négligeables lorsqu'on l'applique à un individu moyen.

Se limiter à la comparaison de ces deux courbes peut donc conduire à une évaluation biaisée de la performance du modèle. En effet, une courbe de survie prédite pour l'individu moyen ne reflète pas nécessairement le comportement observé dans l'ensemble de la population, particulièrement si des facteurs individuels ou des interactions complexes ne sont pas correctement modélisés. Ainsi, pour une évaluation plus robuste, il est essentiel de prendre en compte l'ensemble des individus et d'analyser la performance du modèle sur la population dans son ensemble, plutôt que de se concentrer uniquement sur un seul cas. Cela permet de mieux saisir les biais et les limitations potentiels des modèles utilisés et d'en évaluer véritablement leur capacité à prédire la survie.

Nous compléterons notre analyse de la qualité des modèles en examinant les différents critères énoncés :

Table 4 – Performance des Modèles : Avant la signature d'un contrat

<i>Distributions</i>	<i>AIC</i>	<i>BIC</i>	<i>Concordance</i>	<i>IBS¹</i>
Exponentielle	15548.76	15640.75	0.678618	0.157878
Weibull	15224.18	15322.74	0.678250	0.157285
Log-Normale	15147.39	15245.95	0.678141	0.157142
Log-Logistique	15200.93	15299.48	0.678368	0.156966
Gamma Généralisée	15146.67	15251.80	0.678223	0.157293
Fisher Généralisée	15148.68	15260.38	0.678223	0.157291

¹IBS = Integrated Brier Score

Sur la base des résultats présentés dans le tableau, le choix de la distribution **log-normale** semble être le plus pertinent. En effet, parmi les différentes distributions évaluées, la log-normale présente les valeurs les plus faibles pour l'AIC (à peine plus élevé que pour le modèle utilisant une distribution **gamma généralisée**) et le BIC (15245.95). De plus, sa valeur de concordance (0.678141) est similaire à celles des autres modèles, indiquant une capacité de discrimination comparable. Enfin, son score IBS (0.157142), bien que légèrement plus élevé que le modèle utilisant une distribution **log-logistique**, reste compétitif et relativement proche des valeurs obtenues par les autres distributions.

$$\log(t_i) = X_i\beta + u_i \quad ; \quad u_i \sim \mathcal{N}(0, \sigma^2)$$

Analyse des résultats

Dans le tableau ci-dessous, vous retrouverez les estimations de ce modèle :

Table 6 – Cas 1 : Modèle AFT à distribution log-normale

	Variable dépendante
	Log(t)
Femme (Ref. Homme)	-0.050
Vit avec un(e) partenaire (Ref. Sans partenaire)	1.097***
Vit avec une personne dépendante (Ref. Aucune)	1.094**
Vit avec plusieurs personne dépendante	1.289***
15-24 ans (Ref. > 54 ans)	0.454***
25-34 ans	0.111
35-44 ans	0.244*
45-54 ans	0.252**
Femme x Vit avec un(e) partenaire (Interaction)	0.268
Femme x Vit avec une personne dépendante	0.030
Femme x Vit avec plusieurs personne dépendante	-0.968***
Vit avec un(e) partenaire x Vit avec une personne dépendante	1.000**
Vit avec un(e) partenaire x Vit avec plusieurs personne dépendante	1.627***
Constante	3.962***
AIC	15147.392
BIC	15245.947
Concordance	0.678
IBS	0.157
Observations	5,273
Log Likelihood	-7,558.696
χ^2	610.197*** (df = 13)
Note:	*p<0.1; **p<0.05; ***p<0.01

Interprétations du modèle

On remarque par exemple que le fait d'appartenir à la classe d'âge des 15-24 ans à un effet positif et significatif sur la durée de vie des individus. Ainsi les jeunes de 15 à 24 ans ont une durée de vie plus longue que les individus de plus de 54 ans dans la compagnie.

Enfin toujours selon le modèle le fait de vivre avec un partenaire ainsi que de vivre avec plusieurs personnes dépendantes a un effet positif et significatif sur la durée de vie des individus. Ainsi les individus vivant avec un partenaire ou plusieurs personnes dépendantes ont une durée de vie plus longue que les individus vivant seuls.

L'interaction entre le sexe et la cohabitation avec plusieurs personnes dépendantes montre une forte diminution pour les femmes, suggérant que cet arrangement a un impact plus défavorable sur elles.

Estimations de la valeur des clients

Le montant que le client pourrait payer chaque mois étant inconnu, nous l'estimerons à l'aide d'une régression linéaire basée sur les variables disponibles. Nous n'analyserons pas ici l'effet des covariables. Ainsi, la valeur client que nous allons estimer est donnée par la formule :

$$CLV_i = \sum_{t=1}^T \frac{\text{Monthly Charge}_i * \hat{P}(T_{it} > t)}{(1 + d)^t}$$

Voici les résultats obtenus pour ce contexte :




Figure 15 – Cas 1 : Comparaison observation/prédiction




Figure 16 – Cas 1 : Estimations du modèle

Table 7 – Cas 1 : Estimation de la CLV

T_{obs}	$CLV_{Pessimiste}$	CLV_{est}	$CLV_{Optimiste}$	CLV_{obs}	PM	PM_{est}
Censuré	1893	1916	1930	3519	98	58
59	2149	2214	2272	1809	50	80
53	1342	1403	1467	2660	74	57
40	1882	1922	1945	706	20	59
31	2135	2192	2246	2497	81	77
20	2149	2214	2272	1473	74	80
10	1534	1597	1662	846	85	69
1	1352	1419	1477	20	20	58

PM = Paiements mensuels

Après avoir examiné les résultats, il apparaît clairement que cette première tentative d'estimation de la valeur des clients ne fournit pas des résultats satisfaisants, surtout si l'on les compare à la réalité pour ces huit individus. Plusieurs facteurs expliquent cette inadéquation. Tout d'abord, le manque d'informations sur chaque individu dans ce contexte spécifique limite considérablement la précision des prédictions. En effet, avec des données aussi limitées, les probabilités de survie estimées pour les clients sont trop approximatives, ce qui empêche d'appréhender correctement la dimension de la rétention, essentielle dans l'estimation de la valeur à vie d'un client. Cela se traduit par une faible capacité à prédire la fidélité à long terme, un facteur crucial pour l'entreprise.

Ensuite, une autre difficulté majeure réside dans le fait que nous devons estimer les paiements mensuels de ces clients, comme s'ils étaient sous contrat. Or, ces estimations s'avèrent être très éloignées de la réalité, comme le montre le tableau des résultats. Cette approximation dans l'évaluation des paiements mensuels est problématique, car elle influe directement sur l'estimation de la valeur à vie des clients. En l'absence de données fiables concernant les comportements réels de ces clients, les prédictions restent trop imprécises pour être exploitables dans une stratégie commerciale.

Ainsi, cette première approche met en évidence la nécessité de disposer de données plus complètes et détaillées pour effectuer des prévisions plus fiables. Les variables disponibles dans ce cas sont insuffisantes pour capturer les comportements et les préférences des clients de manière précise. Une meilleure compréhension de ces facteurs permettrait de développer des modèles plus robustes, offrant ainsi une estimation plus précise de la valeur des clients à long terme, ce qui serait essentiel pour affiner les stratégies d'acquisition et de fidélisation.

En sommant l'ensemble des CLV estimées, voici notre valorisation du portefeuille de Telco dans ce premier contexte :

Table 8 – Estimation de la valeur du portefeuille de Telco
 $\sum CLV$

Pessimiste	Normal	Optimiste	Réelle
11885788	12334885	12722158	10462527

Nous surestimons la valeur du portefeuille de client de telco d'environ 2 millions de dollars.

Cas 2 : Les clients signent un contrat avec la compagnie

Dans ce second contexte, le client a désormais signé un contrat d'abonnement avec Telco, ce qui marque un tournant dans la relation entre l'entreprise et le client. En effet, grâce à la signature de ce contrat, Telco dispose d'un ensemble d'informations beaucoup plus détaillées et complètes sur le client. Au-delà des données initiales, l'entreprise connaît désormais des aspects cruciaux de la relation commerciale, tels que le type de contrat souscrit, l'offre choisie, les méthodes de paiement préférées, ainsi que le nombre et la nature des services auxquels le client a souscrit. Ces nouvelles données permettent à Telco d'affiner considérablement l'estimation de la valeur potentielle de ce client, en prenant en compte des éléments qui influencent directement la rentabilité à long terme.


Toutefois, il est important de noter que ces estimations ne sont valides que dans un cadre bien défini : celles-ci ne s'appliquent qu'aux clients ayant effectivement signé un contrat d'abonnement. Cela implique que les prévisions réalisées à partir de ces informations ne peuvent pas être extrapolées à l'ensemble des prospects, et elles sont limitées aux clients actifs qui ont déjà engagé une relation formelle avec l'entreprise. Par conséquent, bien que l'ajout de ces nouvelles données offre une meilleure base pour évaluer la valeur à vie des clients, il est essentiel de comprendre que ces estimations reposent sur l'hypothèse que le client continue à être sous contrat et que son comportement ne dévie pas radicalement de celui observé pour des clients similaires dans le passé.

Cela renforce l'importance de disposer d'un suivi continu de la relation client, et de pouvoir ajuster régulièrement les prévisions de valeur à mesure que de nouvelles données sur le comportement du client deviennent disponibles. Dans ce cadre, l'entreprise pourra mieux orienter ses stratégies de fidélisation et de développement commercial, en se basant sur des prévisions plus réalistes et adaptées aux profils des clients ayant déjà fait le choix de souscrire à un abonnement.

Au travers de l'étude notre base de données, nous avons remarqué qu'un certains nombres de valeurs avaient un pattern régulier, les variables suivantes :

- **Internet Type** : Indique le type de service internet utilisé par le client ;
- **Online Security** : Indique si le client a souscrit à un service de sécurité en ligne supplémentaire proposé par l'entreprise ;
- **Online Backup** : Indique si le client a souscrit à un service de sauvegarde en ligne supplémentaire proposé par l'entreprise ;
- **Device Protection** : Indique si le client a souscrit à un plan de protection des équipements Internet proposé par l'entreprise ;
- **Tech Support** : Indique si le client a souscrit à un plan d'assistance technique supplémentaire avec des temps d'attente réduits ;
- **Streaming TV** : Indique si le client utilise son service Internet (s'il en possède un) pour regarder la télévision en streaming via un fournisseur tiers ;
- **Streaming Movies** : Indique si le client utilise son service Internet (s'il en possède un) pour regarder des films en streaming via un fournisseur tiers ;

contiennent toutes la modalité **No Internet Service** ou **No Phone Service**, ce qui engendre un problème de multicollinéarité pour nos modèles.



Au vu de la matrice de Cramer notre supposition s'est avérée, afin de palier à ceci nous avons opté pour une analyse en composantes multiples.




Figure 17 – Etude des Dimensions

Nous décrirons les résultats de cette acm au travers des 3 premiers axes qui cumulent environ 60% de l'inertie projetée.




Figure 18 – Etude des contributions à l'axe 1




Figure 19 – Etude des contributions aux axes 2 et 3

⚠ Biplot

Les graphiques suivants sont présentés avec un habillage basé sur les variables que nous avons construites à partir de l'ACM. Afin d'améliorer leur lisibilité, un grand nombre d'individus ont été volontairement retirés de la représentation graphique. Toutefois, ce retrait n'affecte en rien l'interprétation des graphiques.




Figure 20 – ACM - Biplot




Figure 21 – ACM - Biplot

En conclusion, Voici les interprétations que nous utiliserons pour ces axes :

- **Axe 1** : Si l'individu prend une valeur positive à l'axe 1, alors celui-ci n'a pas de service internet
- **Axe 2** : Si l'individu prend une valeur supérieur à 0.8 à l'axe 2, alors celui-ci n'a pas de service téléphonique
- **Axe 3** : Plus l'individu a de service plus sa coordonnée à cet axe sera élevé

À partir de ces observations, nous allons déterminer les variables **Service Internet** et **Service Téléphonique** qui détermineront si l'individu possède ces services et nous allons conserver l'axe 3 comme variable à part entière pour déterminer le nombre de service possédés par l'individu.

Sélection du modèle

L'ensemble de variables supplémentaires disponibles dans ce contexte sont :

- **Contract** : La durée stipulée dans le contrat signé ;
- **Payment Method** : La méthode de paiement ;
- **Offer** : Le type d'offre à laquelle le client a souscrit (nous ne possédons pas d'informations sur le contenu de ces offres) ;
- **Monthly Charges** : Le montant payé à chaque mensualité ;
- **Multiple Lines** : Indique si le client possède plusieurs lignes téléphoniques auprès de l'entreprise ;
- **Service Internet** ; **Service Téléphonique** ; **axe3** : Les variables construites avec l'ACM.

Lors de la sélection des variables, la méthode **step_aic** a retenu les variables suivantes :

- **Contract**
- **Payment Method**
- **Partner**
- **N_dependents**
- **Paperless Billing**
- **Offer**
- **Service Internet**
- **Monthly Charges**
- **Service Téléphonique**
- **axe3**

Ainsi que les effets d'interaction :

- **Monthly Charges*Service Téléphonique**
- **Monthly Charges*Service Téléphonique**

Sélection de la distribution




Figure 22 – Cas 2 : Loi Exponentielle (PH et AFT)






Figure 23 – Cas 2 : Loi Weibull (AFT)

**Figure 24** – Cas 2 : Loi Log-Logistique (AFT)**Figure 25** – Cas 2 : Loi Log-Normale (AFT)

Loi Gamma Généralisée




Figure 26 – Cas 2 : Loi Gamma Généralisée (AFT)

Loi Fisher Généralisée




Figure 27 – Cas 2 : Loi Fisher Généralisée (AFT)

Dans ce contexte, nos estimations des fonctions de risque (et, par extension, des fonctions de survie) nous semblent plus pertinentes que lors de l'étude pré-intégration. En effet, nos modèles parviennent mieux à discriminer les individus en fonction de la durée de leur relation avec l'entreprise. De plus, les modèles les plus sophistiqués révèlent des fonctions de risque présentant des pics, plutôt qu'une décroissance stricte. Cette dernière suggérerait une corrélation négative entre le temps de survie et le risque de défaillance, une approche que nous jugions trop simpliste pour refléter fidèlement la réalité.

Table 9 – Performance des Modèles : Après la signature d'un contrat

<i>Distributions</i>	<i>AIC</i>	<i>BIC</i>	<i>Concordance</i>	<i>IBS¹</i>
Exponentielle	12695.87	12833.85	0.8922026	0.070863
Weibull	12672.84	12817.38	0.8924925	0.069462
Log-Normale	12636.94	12820.91	0.8930986	0.071910
Log-Logistique	12648.72	12793.26	0.8929487	0.070873
Gamma Généralisée	12629.65	12780.76	0.8921290	0.070623
Fisher Généralisée	12632.03	12789.71	0.8921290	0.070634

¹IBS = Integrated Brier Score

Un arbitrage entre les différentes métriques nous conduit à privilégier la distribution gamma généralisée. En effet, opter pour la loi de Weibull uniquement sur la base de l'IBS nous semble peu pertinent, étant donné que cette distribution impose une fonction de risque strictement croissante. Bien que le choix entre la distribution gamma généralisée et la distribution log-normale puisse faire l'objet d'un débat, nous constatons que, malgré la complexité de la première, les métriques AIC et BIC lui sont favorables.

$$\log(t_i) = X_i\beta + u_i$$

avec $u_i \sim \mathcal{G}_{\text{gen}}(a, d, p)$ avec $d > 0$ et $p > 0$ représentant deux paramètres de forme et $a > 0$ un paramètre d'échelle. Ainsi les fonctions de survie et de risque sont :

$$S(t) = 1 - \frac{\gamma(d/p; (x/a)^p)}{\Gamma(d/p)} \quad ; \quad \lambda(t) = \frac{p/a^d \cdot x^{d-1} e^{-(x/a)^p}}{\Gamma(d/p) - \gamma(d/p; (x/a)^p)}$$

avec $\Gamma(\cdot)$ et $\gamma(\cdot)$ les fonctions gamma et gamma incomplète.

Analyse des résultats

Table 11 – Cas 2 : Modèle AFT à distribution Gamma Généralisée

	Variable dépendante = $\text{Log}(t)$
μ	4.6830*** (0.3952)
σ	0.1622*** (0.0463)
Q	0.3572*** (0.0926)
A signé un contrat d'une année (Ref. renouvelable chaque mois)	1.2977*** (0.0903)
Deux années	2.2641*** (0.1416)
Paie par carte de crédit (automatique) (Ref. Virement automatique)	0.0459 (0.0964)
Par chèque électronique	-0.5084 (0.0780)
Par mail	-0.5917 (0.0944)
Vit avec un(e) partenaire (Ref. Sans partenaire)	0.2926*** (0.0576)
Vit avec une personne dépendante (Ref. Aucune)	-0.8787 (0.1173)
Vit avec plusieurs personnes dépendantes	0.0594 (0.1873)
Paiement sans papier (Ref. Avec papier)	-0.1527 (0.0613)
A souscrit à l'offre A (Ref. Aucune)	0.5936*** (0.1704)
Offre B	1.2022*** (0.1108)
Offre C	0.7824*** (0.1198)
Offre D	0.3303*** (0.1040)
Offre E	-1.5038 (0.0767)
A un service Internet (Ref. Non)	1.1324*** (0.2090)
Montant des Paiements mensuels	-0.0401 (0.0105)
A un service téléphonique (Ref. Non)	0.6519* (0.3633)
Coordonnée sur l'axe factoriel 3 (croît avec le nombre de services souscrits)	3.2183*** (0.3274)
Montant des Paiements mensuels X A un service téléphonique	0.0212** (0.0096)
Montant des Paiements mensuels X Coordonnée sur l'axe factoriel 3	-0.0240 (0.0036)

<i>AIC</i>	12629.6457
<i>BIC</i>	12780.7638
<i>Concordance</i>	0.8921
<i>IBS</i>	0.0706
<i>Observations</i>	5273.0000
$\hat{L}$	-6291.8228

Interprétations du modèle

- Les résultats montrent clairement que la durée d'engagement contractuel influence significativement la propension des clients à rester abonnés. En particulier, les clients ayant signé un contrat d'un an ou de deux ans présentent une probabilité de résiliation bien plus faible que ceux dont le contrat est renouvelable chaque mois. Ce constat est intuitif : un engagement plus long réduit mécaniquement les opportunités de résiliation et favorise une fidélisation plus marquée. De plus, ces clients peuvent percevoir un avantage économique ou un confort administratif à ne pas avoir à renouveler fréquemment leur contrat, ce qui les incite à rester plus longtemps.
- Le type d'offre choisie par le client apparaît comme un facteur clé dans son comportement futur. Certaines offres semblent être associées à une meilleure rétention, probablement parce qu'elles apportent une valeur perçue plus élevée ou répondent mieux aux besoins des clients. À l'inverse, d'autres offres, comme l'offre E, semblent être corrélées à une propension plus élevée à la résiliation. Cela pourrait s'expliquer par un moindre niveau de satisfaction, un rapport qualité-prix moins avantageux ou encore un public cible plus volatile.
- L'adhésion à divers services dès le départ joue un rôle fondamental dans la relation future entre le client et l'entreprise. Le modèle indique que les clients qui souscrivent à un éventail plus large de services (téléphonie, internet, etc.) ont tendance à rester abonnés plus longtemps. Cette observation est cohérente avec l'idée que la multiplication des services crée des barrières à la sortie : plus un client dépend des services d'un opérateur, plus il lui est coûteux de changer de fournisseur. Cette captation est encore renforcée lorsque le client signe un contrat de longue durée, ce qui réduit davantage sa flexibilité de départ.
- Le montant des paiements mensuels joue un rôle ambivalent. D'une part, des paiements plus élevés peuvent être perçus comme une charge financière plus lourde, augmentant ainsi le risque de résiliation. D'autre part, lorsque ces paiements sont liés à un nombre plus important de services souscrits, ils semblent au contraire favoriser la fidélisation. Ce phénomène peut s'expliquer par une plus grande satisfaction due à une utilisation accrue des services, renforçant ainsi l'attachement au fournisseur.




Figure 28 – Cas 2 : Comparaison observation/prédiction

Naturellement, ce modèle est bien plus performant, attention cependant à ne pas omettre certaines estimations qui s'éloignent grandement de la réalité, il est possible que le comportement de certains clients soient imprévisibles avec les informations que nous avons à disposition.




Figure 29 – Cas 2 : Estimations du modèle

Dans notre échantillon d'observation, nous constatons un changement radical des fonctions de survie et de risque estimées. L'ajout de nouvelles variables permet au modèle de mieux capturer le comportement potentiel des clients, améliorant ainsi sa capacité à les discriminer. De plus, il est désormais en mesure de modéliser des fonctions de survie nettement plus faibles pour les individus ayant résilié précocement.

Table 13 – Cas 2 : Estimation de la CLV

T_{obs}	$CLV_{Pessimiste}$	CLV_{est}	$CLV_{Optimiste}$	CLV_{obs}	PM
Censuré	3179.75141	3255.24965	3258.23297	3261.49730	97.75
60	1007.57128	1154.74683	1256.02826	1676.62649	50.25
50	2390.21460	2457.42642	2460.87077	2465.72532	73.90
40	645.12248	653.70555	653.87415	653.96775	19.60
30	2307.81644	2336.90686	2337.51058	2337.94734	80.55
20	836.69109	906.90742	952.46080	1410.47912	73.65
10	689.22422	744.97685	758.99250	826.93130	84.60
1	16.91638	18.51154	18.86206	20.11618	20.20

PM = Paiements mensuels

Nous observons une amélioration significative de l'estimation de la CLV. En effet, l'intégration de nouvelles variables permet une meilleure prise en compte de la dimension rétention des clients, tout en tenant compte du montant des paiements mensuels effectués par chacun d'eux.

Grâce à cette approche, nous sommes en mesure d'obtenir une vision plus précise et affinée de la valeur des clients sur la durée. Par ailleurs, nos résultats s'avèrent suffisamment concluants pour affirmer que l'analyse de survie constitue un outil pertinent et efficace pour estimer la valeur client. Cette méthodologie permet non seulement de mieux anticiper les comportements de résiliation, mais aussi d'optimiser les stratégies de fidélisation et de maximiser la rentabilité à long terme.

Table 14 – Estimation de la valeur du portefeuille de Telco
 ΣCLV

Pessimiste	Normal	Optimiste	Réelle
11257625	11684959	12074070	10462527

Notre estimation de la valeur du portefeuille client de Telco s'est également améliorée de manière significative par rapport à l'étude réalisée avant l'intégration des nouvelles variables. En effet, l'écart entre nos estimations et la réalité, qui était d'environ 2 millions de dollars, s'est réduit à 1,2 million de dollars.

Cas 3 : Etude Post-intégration

Ce troisième et dernier cas d'étude se distingue par le fait que l'entreprise dispose d'informations sur la satisfaction des clients concernant les services fournis ainsi que les montants payés. En effet, un client insatisfait présente un risque de résiliation plus élevé durant sa période de mécontentement. Or, Telco, grâce à une enquête menée auprès de sa clientèle, pourrait être en mesure de détecter cette insatisfaction et de l'associer à certaines caractéristiques de la relation client.

Cependant, une limite importante de cette étude réside dans l'absence d'une mesure continue du niveau de satisfaction au fil du temps. Les données dont nous disposons supposent que la variable **Satisfaction Score** ne fournit pas d'indication précise sur la période à laquelle elle a été recueillie. Il est donc raisonnable de considérer que cette variable reflète un niveau de satisfaction global plutôt qu'une évaluation dynamique au cours de la relation client. Toutefois, si cette satisfaction est mesurée en fin de relation, elle pourrait être biaisée négativement, car l'individu vient de résilier et pourrait exprimer un mécontentement accru au moment de l'enquête.

Ainsi, bien que l'inclusion de cette variable apporte un éclairage intéressant sur le comportement des clients, son interprétation doit être faite avec prudence afin d'éviter des conclusions erronées.

Nous réutiliserons les mêmes variables et nous rajoutons la variable **Satisfaction Score** que nous sommes en mesure de calculer après avoir sondé la clientèle








Figure 30 – Cas 3 : Loi Exponentielle (PH et AFT)

**Figure 31** – Cas 3 : Loi Weibull (AFT)**Figure 32** – Cas 3 : Loi Log-Logistique (AFT)

**Figure 33** – Cas 3 : Loi Log-Normale (AFT)**Figure 34** – Cas 3 : Loi Gamma Généralisée (AFT)




Figure 35 – Cas 3 : Loi Fisher Généralisée (AFT)

Table 15 – Performances des Modèles : Après l'enquête de satisfaction

<i>Distributions</i>	<i>AIC</i>	<i>BIC</i>	<i>Concordance</i>	<i>IBS¹</i>
Exponentielle	11162.70	11300.68	0.9390096	0.053558
Weibull	11083.78	11267.75	0.9393911	0.051707
Log-Normale	11060.54	11251.08	0.9407069	0.051997
Log-Logistique	11077.39	11267.93	0.9405713	0.051734
Gamma Généralisée	11013.12	11203.66	0.9360640	0.051626
Fisher Généralisée	11015.12	11212.23	0.9360650	0.051626

¹IBS = Integrated Brier Score

Nous optons une nouvelle fois pour la distribution Gamma Généralisée dans cette étude post-intégration, en raison de ses performances sur l'AIC et le BIC. Il est également important de noter que toutes les distributions étudiées ont vu leurs performances s'améliorer depuis l'intégration de la variable **Satisfaction Score**. Cela confirme que le niveau de satisfaction est une information précieuse, permettant une meilleure modélisation du comportement des clients et une estimation plus fine des fonctions de survie et de risque.

Analyse des résultats

Table 17 – Cas 3 : Modèle AFT à distribution Gamma Généralisée

	Variable dépendante = $\text{Log}(t)$
μ	1.7357*** (0.3737)
σ	-0.0221** (0.0268)
Q	0.4625*** (0.0623)
A signé un contrat d'une année (Ref. renouvelable chaque mois)	0.7838*** (0.0868)
Deux années	1.5772*** (0.1368)
Paie par carte de crédit (automatique) (Ref. Virement automatique)	0.1345 (0.0915)
Par chèque électronique	-0.2948 (0.0727)
Par mail	-0.4904 (0.0882)
Vit avec un(e) partenaire (Ref. Sans partenaire)	0.3569*** (0.0525)
Vit avec une personne dépendante (Ref. Aucune)	-0.4312 (0.1126)
Vit avec plusieurs personnes dépendantes	0.1984 (0.1830)
Paiement sans papier (Ref. Avec papier)	-0.0646 (0.0574)
A souscrit à l'offre A (Ref. Aucune)	0.4390** (0.1636)
Offre B	0.9601*** (0.1066)
Offre C	0.6601*** (0.1096)
Offre D	0.3751*** (0.0952)
Offre E	-1.3101 (0.0665)
Niveau de satisfaction (1 à 5)	1.0634*** (0.2009)
A un service Internet (Ref. Non)	-0.0312 (0.0099)
Montant des Paiements mensuels	0.1114* (0.3388)
A un service téléphonique (Ref. Non)	2.6550*** (0.3124)
Coordonnée sur l'axe factoriel 3 (croît avec le nombre de services souscrits)	0.8555*** (0.0276)
Montant des Paiements mensuels X A un service téléphonique	0.0229*** (0.0091)
Montant des Paiements mensuels X Coordonnée sur l'axe factoriel 3	-0.0186** (0.0034)

<i>AIC</i>	11016.8209
<i>BIC</i>	11174.5094
<i>Concordance</i>	0.8921
<i>IBS</i>	0.0706
<i>Observations</i>	5273.0000
$\hat{L}$	-5484.4105

Interprétations du modèle

Par rapport au modèle précédent, cette version post-intégration met en évidence plusieurs évolutions notables dans les facteurs influençant la rétention des clients. L'introduction d'une nouvelle variable, le niveau de satisfaction (noté de 1 à 5), constitue une différence majeure, avec un effet fortement positif et significatif (coefficient de 1.0634), soulignant son rôle central dans la fidélisation. Parallèlement, bien que les contrats d'un an et de deux ans continuent d'avoir un impact protecteur contre la résiliation, leur influence est légèrement réduite (0.7838 vs. 1.2977 et 1.5772 vs. 2.2641), suggérant que post-intégration, la rigidité contractuelle cède du terrain à d'autres déterminants comme la satisfaction et les services souscrits.

L'effet du service téléphonique sur la rétention s'est fortement accru (2.6550 contre 0.6519 précédemment), indiquant qu'après l'intégration, les clients bénéficiant de ce service sont beaucoup moins susceptibles de résilier, tandis que le service internet, autrefois un facteur protecteur, ne joue plus de rôle significatif dans cette version du modèle. Concernant les offres, leurs coefficients restent significatifs mais évoluent : si les offres B, C et D conservent un effet protecteur, leur impact est légèrement réduit, l'offre A voit son influence diminuer, tandis que l'offre E reste associée à un risque élevé de résiliation (coefficient de -1.3101).

Enfin, un effet d'interaction intéressant émerge : à nombre de services souscrits constant (variable "axe 3" fixée), une augmentation du montant des paiements mensuels tend à réduire la probabilité de rétention, un résultat cohérent avec la loi de l'offre et de la demande, suggérant que des prix plus élevés, en l'absence de services additionnels, peuvent inciter les clients à résilier.

Nous terminerons ces interprétations en remarquant que l'ajout de la variable **Satisfaction Score** bouleverse l'estimation des coefficients de ce modèle et semble peser très lourd. Malheureusement, c'est la seule variable représentant une réalité relative à chaque individu et nous permettant de capturer l'hétérogénéité présente dans nos données, il sera donc difficile d'améliorer les capacités d'estimation de ce modèle au-delà de ce contexte si nous ne récoltons pas davantage d'informations sur nos clients.




Figure 36 – Cas 3 : Comparaison observation/prédiction

Graphiquement, il est difficile de constater une nette amélioration de notre modèle mais nous noterons tout de même que les individus “mal prédits” semblent un peu mieux prédits dans ce contexte.




Figure 37 – Cas 3 : Estimations du modèle

La comparaison des courbes de survie entre le cas numéro 2 et cette étude post-intégration met en évidence des différences marquées. L'évolution de la courbe de survie estimée pour un individu ayant résilié dès le premier mois est particulièrement frappante : celle-ci subit une chute brutale dès le premier mois, indiquant un risque de résiliation extrêmement élevé sur cette période, estimé à environ 30 %.

Cette observation suggère que le nouveau modèle améliore encore la capacité de discrimination des individus en identifiant plus finement les profils à fort risque de résiliation. Toutefois, bien que ces résultats indiquent une meilleure capture des comportements des clients, ils ne permettent pas d'affirmer avec certitude que le modèle est globalement supérieur.

Table 19 – Cas 3 : Estimation de la CLV

T_{obs}	$CLV_{Pessimiste}$	CLV_{est}	$CLV_{Optimiste}$	CLV_{obs}	PM
Censuré	3248.67831	3255.39211	3258.7943	3261.49730	97.75
60	1562.11033	1599.96618	1626.8694	1676.62649	50.25
50	2461.88634	2463.97767	2465.0453	2465.72532	73.90
40	653.81935	653.91988	653.9556	653.96775	19.60
30	2337.40755	2337.75402	2337.8973	2337.94734	80.55
20	431.53283	484.76937	541.1021	1410.47912	73.65
10	792.43195	799.97400	806.2300	826.93130	84.60
1	15.49879	16.54729	17.3953	20.11618	20.20

PM = Paiements mensuels

Les estimations de la CLV obtenues avec ce modèle sont globalement satisfaisantes. Elles se révèlent particulièrement précises pour certains profils de clients, notamment ceux dont l'horizon de résiliation est censuré ou ayant résilié après 50 ou 60 mois.

En revanche, le modèle semble moins performant pour d'autres segments, notamment les clients ayant résilié plus tôt, après 10 ou 20 mois. Cette variabilité des performances suggère que, bien que le modèle capture efficacement la valeur de certains clients, des ajustements pourraient être nécessaires pour affiner l'estimation sur les durées de vie plus courtes.

Table 20 – Estimation de la valeur du portefeuille de Telco
 ΣCLV

Pessimiste	Normal	Optimiste	Réelle
11782918	12121729	12427928	10462527

Globalement, ce modèle semble produire des estimations de la CLV moins précises que celles obtenues dans le contexte numéro 2, mais plus précises que celles issues de l'étude pré-intégration (contexte numéro 1).

Une des raisons majeures de cette variabilité réside dans l'impact considérable de la variable **Satisfaction Score** sur les estimations effectuées par le modèle. Cette variable semble jouer un rôle déterminant, ce qui soulève une limite importante : la satisfaction client est une dimension dynamique et évolutive, or, notre modèle repose sur une mesure ponctuelle, ce qui peut biaiser l'interprétation des résultats.

En effet, la CLV est estimée sur une période de 36 mois, et il est évident que le niveau de satisfaction d'un client peut varier considérablement durant cet intervalle. Déterminer qu'un client est satisfait à un instant donné (par exemple, après 3 mois) ne permet pas d'affirmer qu'il le restera durant les années suivantes. Cette approche ponctuelle limite donc la capacité du modèle à capturer avec précision l'impact réel de la satisfaction sur la rétention et la valeur client.

Pour améliorer la fiabilité des estimations de CLV et tirer un meilleur parti de la variable Satisfaction Score, nous recommandons à TELCO de mettre en place un suivi longitudinal de la satisfaction client. Concrètement, cela impliquerait :

- Réaliser des enquêtes de satisfaction à plusieurs intervalles de temps (par exemple, trimestriellement ou semestriellement).
- Associer ces mesures à des événements clés de la relation client, comme une modification de l'offre, une interaction avec le service client ou un incident technique.
- Modéliser l'évolution de la satisfaction au lieu de l'utiliser comme une valeur statique, afin d'intégrer son impact dans la durée sur la probabilité de résiliation et la CLV.

Conclusion

L'estimation de la valeur d'un client est un exercice complexe qui nécessite l'exploitation d'une quantité massive de données et la prise en compte de nombreuses variables. L'une des principales limites de notre étude réside dans l'incapacité à mesurer l'impact de la concurrence, un facteur clé qui influence directement la rétention des clients. De plus, notre analyse repose sur la base de données TELCO d'IBM, qui, bien qu'exhaustive, ne reflète pas la réalité du terrain, notamment en raison de l'absence de données manquantes. Or, dans un contexte opérationnel, il est rare de disposer d'informations complètes, notamment sur des variables subjectives comme le **Satisfaction Score**. Un autre défi de notre approche tient au fait que nous tentons d'estimer la valeur des clients sur une période de trois ans, alors que certaines variables essentielles évoluent au fil du temps, ce qui peut affecter la robustesse des prédictions. Malgré ces limites, nos modèles se sont révélés très performants sur certains segments de clientèle, bien que l'hétérogénéité des clients, omniprésente dans la réalité, ait pu biaiser certains résultats. Ces constats mettent en lumière l'importance d'une approche dynamique, intégrant des mises à jour régulières des données et une prise en compte plus fine des comportements des clients. L'analyse de survie apparaît comme un outil particulièrement puissant et sous-exploité dans ce cadre, et son approfondissement pourrait jouer un rôle clé dans l'optimisation des stratégies de fidélisation et de gestion du cycle de vie client.

Analyse de Survie

Introduction

L'**analyse de survie**, également connue sous le nom d'analyse des durées ou time-to-event analysis, est une branche des statistiques dédiée à l'étude du temps avant la survenue d'un événement spécifique. Cette méthode est essentielle pour comprendre et modéliser les phénomènes où la variable d'intérêt est le temps écoulé avant un événement critique. Bien que l'un des contextes les plus courants de cette analyse soit l'étude du temps jusqu'à la mort en biomédecine, son application s'étend à de nombreux autres domaines tels que la fiabilité des machines, l'actuariat, la psychologie, l'économie et même le marketing.

Un aspect fondamental de l'analyse de survie est sa capacité à traiter des **données censurées**. La censure survient lorsque le temps exact de l'événement d'intérêt n'est pas observé pour certains individus, soit parce qu'ils n'ont pas encore connu l'événement à la fin de l'étude, soit parce qu'ils sont perdus de vue avant que celui-ci ne survienne. La gestion de ces données partielles est cruciale dans les modèles de survie, car elle permet de maintenir la validité des résultats sans biaiser les estimations.

Les méthodes classiques d'analyse de survie incluent les fonctions de **survie et de risque**, qui permettent d'évaluer la probabilité qu'un individu ou un système survive au-delà d'un certain point dans le temps, ainsi que le taux auquel l'événement d'intérêt survient. Une des techniques les plus connues est la méthode de **Kaplan-Meier**, qui permet d'estimer la fonction de survie en fonction du temps sans faire d'hypothèse sur la distribution des durées. Pour des modèles plus complexes, le modèle de régression de **Cox** est fréquemment utilisé. Ce modèle semi-paramétrique intègre des variables explicatives, permettant ainsi de comprendre l'influence de facteurs comme le traitement médical ou l'âge sur le risque de survenue d'un événement.

Au-delà des applications biomédicales, l'analyse de survie s'est révélée indispensable en ingénierie, notamment dans l'évaluation de la durée de vie des composants et des systèmes, appelée fiabilité ou durée de vie utile. En économie et en finance, elle permet d'étudier les durées jusqu'à la faillite d'entreprises ou les délais entre des décisions d'investissement. Dans le domaine du marketing, elle aide à comprendre la fidélité des clients en analysant le temps avant qu'ils ne cessent d'utiliser un produit ou un service.

L'histoire de l'analyse de survie remonte aux tables de mortalité du 17^e siècle, lorsqu'Edmund Halley, célèbre pour la comète qui porte son nom, a été parmi les premiers à estimer la probabilité de survie en fonction de l'âge à partir de données

démographiques. Ces premières approches ont jeté les bases de la biostatistique moderne. Depuis, l'analyse de survie a considérablement évolué avec l'introduction de méthodes statistiques sophistiquées et de puissants outils informatiques, permettant d'analyser des données de plus en plus complexes dans divers secteurs.

Ainsi, l'analyse de survie est devenue un pilier essentiel dans la prise de décision basée sur des données temporelles, apportant des réponses précises aux questions sur la durée et le risque dans une multitude de contextes. Que ce soit pour prévoir la durée de vie d'un produit, estimer l'impact d'un traitement médical ou modéliser le risque de défaillance d'un système, l'analyse de survie offre des solutions statistiques robustes adaptées à la réalité de données incomplètes et censurées.

Modèles de durée

Les modèles de durée sont ceux utilisés lors d'analyse de survie, car ils permettent de modéliser et d'analyser le temps écoulé avant la survenue d'un événement. Les concepts probabilistes ainsi que des fonctions statistiques nous permettent de modéliser ces durées. La variable de réponse de ce modèle est le temps jusqu'à l'événement que nous cherchons à prédire, elle est communément appelée **temps de défaillance** (failure time) et elle est notée T .

On retrouve bien sûr la **fonction de répartition** noté $F(t)$ qui décrit la probabilité que l'événement se produise avant le temps t .

$$F(t) = \mathbb{P}(T \leq t) ; \forall t > 0$$

Ainsi que la **densité de probabilité** $f(t)$ représentant la probabilité que l'événement survienne à un instant précis, et peut être obtenue en dérivant la fonction de répartition.

$$f(t) = \frac{dF(t)}{dt}$$

Cette densité est utilisée pour analyser la distribution des durées d'une population donnée.

Les nouveaux concepts introduit dans ce domaine sont la **fonction de survie**, la **fonction de risque instantanée** et le **taux de risque cumulé**.

La **fonction de survie** $S(t)$ représente la probabilité qu'un individu ou un objet survive jusqu'à un temps donné t , et est formellement définie comme :

$$S(t) = \mathbb{P}(T > t) = 1 - F(t) ; \forall t > 0$$

où T est la variable aléatoire qui représente le temps de survie. Cette fonction est généralement décroissante, car la probabilité de survie diminue au fur et à mesure que le temps progresse (Saint-Pierre, P. (2015)).

Quant à la **fonction de risque instantanée** également appelée **fonction de hazard**, elle quantifie la probabilité instantanée de l'occurrence de l'événement à un moment donné t , conditionné au fait que l'individu ait survécu jusqu'à ce point. Elle est utilisée pour modéliser la manière dont le risque de défaillance évolue au fil du temps, elle est formellement définie comme :

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{\mathbb{P}(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t} = \frac{f(t)}{S(t)} = -\frac{d \ln S(t)}{dt}$$

Enfin, le **taux de risque cumulé** $H(t)$ est l'intégrale du risque instantané au fil du temps. Il représente la somme cumulée des risques encourus jusqu'à un temps donné et est exprimé par

$$H(t) = \int_0^t h(u) du$$

On peut donc reformuler la fonction de survie comme suit $S(t) = \exp(-H(t))$ illustrant ainsi la relation étroite entre la survie et l'accumulation des risques.

Espérance de vie et variance

Outre ces fonctions fondamentales, l'espérance et la variance des durées de survie sont des paramètres statistiques importants. L'**espérance de vie**, notée $E(T)$, correspond à la moyenne du temps de survie dans une population donnée et se calcule comme l'intégrale de la fonction de survie :

$$\mathbb{E}(T) = \int_0^\infty S(t) dt$$

La **variance** $V(T)$, quant à elle, mesure la dispersion des durées de vie autour de leur moyenne et est définie par :

$$V(T) = 2 \int_0^\infty t S(t) dt - \mathbb{E}(T)^2$$

Ces deux mesures permettent d'analyser de manière plus approfondie la distribution des temps de survie, en tenant compte de leur moyenne et de leur variabilité.

Censure et troncature

Lorsque l'on décide de s'aventurer dans ce domaine, on aperçoit très rapidement l'une des barrières majeures : **les données censurées**, c'est-à-dire que les données contiennent des observations pour lesquelles l'événement d'intérêt n'est pas complètement observé. Par exemple, dans un essai clinique où l'on suit des patients jusqu'à ce qu'ils décèdent ou guérissent, il se peut que certains patients soient encore en vie à la fin de l'étude. Ne pas prendre en compte cette censure affecte la précision

des estimations des modèles de survie et conduit à des conclusions erronées sur les facteurs influençant la durée de survie.

Cette dernière revêt trois formes :

- **La censure à droite**, les événements sont observés jusqu'à un certain point dans le temps, plusieurs cas de censure à droite existent :
 - **La censure administrative**, elle se produit lorsque toutes les observations cessent d'être suivies à la fin de l'étude ;
 - **La censure par perte de suivi**, dans ce cas, certaines observations sont perdues de vue avant la fin de l'étude ;
 - **La censure par événement concurrent**, un événement autre que celui d'intérêt se produit et vient empêcher l'observation de ce dernier ;
 - **La censure par retrait**, dans ce cas une observation se retire volontairement de l'étude.
- **La censure à gauche**, celle-ci se pose comme un manque d'information survenant avant le point de départ de la période étudiée :
 - **La censure par début tardif de l'étude**, elle se produit lorsque l'étude commence après que certains événements d'intérêt se soient déjà produits.
 - **La censure par manque d'information initiale**, elle se produit lorsque des informations sur les événements d'intérêt avant le début de l'étude ne sont pas disponibles.
 - **La censure par événement antérieur non observé**, elle se produit lorsque des événements d'intérêt se sont produits avant le début de l'étude, mais n'ont pas été observés ou enregistrés.
- **La censure par intervalle** : l'événement s'est produit entre deux moments d'observation, mais nous ne savons pas précisément à quel moment. Ce type de censure est fréquent lorsque les observations ne sont faites qu'à intervalles réguliers.

La troncature est un autre phénomène important en analyse de survie, mais distinct de la censure. Elle se produit lorsque certaines observations sont exclues de l'étude en raison de leurs caractéristiques temporelles. Par exemple, dans une étude sur la longévité d'une population, si les individus nés après une certaine date sont ignorés (car ils sont trop jeunes pour être étudiés), cela représente une troncature à droite. Il existe également une troncature à gauche, qui se produit lorsque les individus dont l'événement est survenu avant une certaine période ne sont pas inclus dans l'étude. Par exemple, si l'étude ne considère que les individus qui ont survécu au-delà d'un certain âge, ceux décédés avant cette limite sont tronqués.




Figure 38 – Représentation des types de censures possibles dans les études de survie.

En analyse de survie deux approches général sont utilisées : la méthode non-paramétrique et paramétrique. Les méthodes paramétriques induisent que la variable d'exécution de l'événement provient d'une famille de distribution spécifique, là où les méthodes non-paramétriques ne font pas de supposition à ce sujet. Nous présenterons aussi le modèle de Cox résultant d'une approche semi-paramétrique.

Modèles non-paramétriques

Contrairement aux modèles paramétriques, les **modèles non-paramétriques** ne font pas d'hypothèses précises sur la forme de la distribution des durées. Ils sont particulièrement utiles lorsqu'il n'est pas possible ou souhaitable de supposer une forme particulière pour la distribution des temps de survie. Cependant, ils ne peuvent être utilisés que dans un but descriptif, car ils ne permettent pas de faire des prédictions sur de nouvelles données. Parmi les modèles non-paramétriques les plus couramment utilisés, on trouve :

L'**estimateur de Kaplan-Meier** (Kaplan, E. L., et Meier, P. (1958)) est l'un des outils non-paramétriques les plus populaires pour estimer la fonction de survie à partir de données censurées. Cet estimateur est basé sur un produit limite, calculé à chaque moment où un événement est observé. La formule de l'estimateur est :

$$\hat{S}(t) = \prod_{i:t(i) \leq t} \left(1 - \frac{d_i}{n_i}\right)$$

où d_i est le nombre de décès au temps $T(i)$, et n_i est le nombre de sujets encore à risque juste avant $t(i)$. Cet estimateur en escalier permet de modéliser les données de sur-

vie tout en tenant compte des observations censurées, c'est-à-dire des individus pour lesquels l'événement d'intérêt n'a pas été observé avant la fin de l'étude.

L'**estimateur de Nelson-Aalen** est une méthode non-paramétrique qui permet d'estimer le taux de risque cumulé. Cet estimateur repose également sur une formule en escalier, semblable à celle de Kaplan-Meier, mais il se concentre sur l'estimation du taux de hasard cumulé :

$$\hat{\Lambda}(t) = \sum_{i:t(i) \leq t} \frac{d_i}{n_i}$$

où d_i représente le nombre d'événements au temps $t(i)$ et n_i est le nombre d'individus encore à risque juste avant $t(i)$. Cette méthode est particulièrement utile pour analyser les données censurées et obtenir une estimation du risque cumulé au fil du temps.

Modèles paramétriques

Les **modèles paramétriques** font des hypothèses spécifiques concernant la forme de la distribution des temps de survie. Ils nécessitent donc de définir une distribution particulière pour modéliser les durées. Voici une liste de distribution couramment utilisés, cités dans les travaux de Taketomi, N., Yamamoto, K., Chesneau, C., et Emura, T. (2021) et Rodríguez, G. (2010) :

Modèle à distribution exponentielle

La **loi exponentielle** est le modèle paramétrique le plus simple, dans lequel $T \sim \mathcal{E}(\lambda)$ et le risque instantané $h(t)$ reste constant au fil du temps ce qui peut être exprimé par :

$$S(t) = e^{-\lambda t} \quad ; \quad h(t) = \lambda$$

où λ est un paramètre constant représentant le taux de risque de base. Ce modèle est souvent utilisé pour des événements aléatoires et imprévus, où la probabilité de l'événement ne dépend pas du temps écoulé. Ce qui signifie que l'individu ou l'objet n'a pas plus de chances de subir l'événement à un moment donné qu'à un autre. Cependant, il ne permet pas de modéliser des situations où le taux de risque varie dans le temps (croissant ou décroissant), ce qui limite son utilité dans certains contextes.

Afin d'imager cela imaginons que nous étudions la durée de vie des ampoules électriques dans une usine. Si la durée de vie des ampoules suit une distribution exponentielle, cela signifie que la probabilité qu'une ampoule grille à un instant donné est constante, peu importe depuis combien de temps elle est en fonctionnement.

Il existe plusieurs extensions de la loi exponentielle qui permettent de modéliser des situations plus complexes, où le taux de risque varie avec le temps. Parmi elles, nous pouvons citer la **loi exponentielle par morceaux**, la **loi exponentielle généralisée** proposée par Gupta et Kundue ou encore la **loi exponentielle logarithmique**.

Modèle à distribution de Weibull

Une distribution de **Weibull** est une distribution de probabilité continue où la relation entre le risque et le temps est monotone, on fait l'hypothèse que $T \sim W(\lambda, k)$, ce qui se traduit par la fonction de survie et le risque suivant :

$$S(t) = \exp(-\lambda t^k) \quad ; \quad h(t) = k\lambda t^{k-1}$$

où k le paramètre de forme peut prendre trois plages de valeurs :

- $k < 1$ signifiant donc que le risque est décroissant et donc que l'événement est plus susceptible d'arriver dans un temps proche.
- $k = 1$ signifiant que le temps n'a aucun impact significatif sur le risque, cela revient à une distribution exponentielle.
- $k > 1$ signifiant ici que le risque est croissant et que donc le risque de défaillance augmente avec le temps.

Afin d'illustrer cela dans le cas de la probabilité pour une personne de contracter la maladie d'Alzheimer, nous pourrions donc envisager un paramètre de forme supérieur à 1. En effet, le risque de contracter la maladie augmente de manière concomitante avec le temps

Il existe plusieurs extensions de la loi Weibull qui permettent de modéliser des situations plus complexes, où le taux de risque varie avec le temps. Parmi elles, nous pouvons citer la **loi Weibull exponentielle** proposé par Nadarajah et Gupta, la **loi "G-modified Weibull"** proposée par Carrasco et al. ou encore la **distribution de Rayleigh** correspondant au cas où $k = 2$.

Modèle à distribution Gamma

Nous pouvons aussi utiliser la distribution Gamma avec comme paramètres λ et k , tels que $T \sim \Gamma(\lambda, k)$, la densité sera donc :

$$f(t) = \frac{\lambda(\lambda t)^{k-1} e^{-\lambda t}}{\Gamma(k)}$$

Les fonctions de survie et de hasard s'écrivent de cette manière :

$$S(t) = 1 - I_k(\lambda t) \quad ; \quad h(t) = \frac{f(t)}{S(t)} = \frac{\frac{\lambda(\lambda t)^{k-1} e^{-\lambda t}}{\Gamma(k)}}{1 - I_k(\lambda t)}$$

où $I_k(x)$ est la fonction Gamma incomplète, définie comme :

$$I_k(t) = \int_0^t \frac{\lambda^{k-1} e^{-\lambda u} du}{\Gamma(k)}$$

- **$k = 1$** La distribution Gamma se réduit à la distribution exponentielle, qui peut être décrite comme le temps d'attente jusqu'à un événement dans un processus de Poisson.
- **$k > 1$** La distribution Gamma est appelée la distribution d'Erlang et peut être caractérisée comme le temps d'attente jusqu'à k événements dans un processus de Poisson. Si nous voulons modéliser le temps d'attente jusqu'à ce que 3 événements soient traités. La distribution d'Erlang est utilisée avec $k = 3$
- La **loi Gamma généralisée** est une extension du modèle Gamma, qui offre une grande flexibilité pour modéliser une variété de formes de survie. Ce modèle est particulièrement utile lorsqu'il existe des données de survie complexes, car il englobe plusieurs distributions paramétriques classiques comme des cas particuliers. La forme générale de la densité de probabilité est donnée par :

$$f(t) = \frac{\lambda p (\lambda t)^{p-1} e^{-(\lambda t)^p}}{\Gamma(p)}$$

La loi Gamma généralisée est un modèle très flexible, et ses cas particuliers incluent plusieurs distributions bien connues, utilisées couramment dans l'analyse de survie et de fiabilité. Voici les principaux cas particuliers :

- **loi gamma**: lorsque $p = 1$,
- **loi de Weibull**: lorsque $p = 1/k$, la loi Gamma généralisée se transforme en la loi de Weibull, qui est souvent utilisée pour modéliser des durées de vie où le taux de risque varie avec le temps.
- **loi exponentielle**: lorsque $p = 1$ et $k = 1$, la loi Gamma généralisée se réduit à la distribution exponentielle, qui est souvent utilisée pour modéliser des événements aléatoires et imprévus.

Modèle à distribution log-normale

La **loi log-normale** est utilisée lorsque les temps de survie suivent une distribution log-normale, c'est-à-dire lorsque le logarithme des temps de survie suit une distribution normale ($\ln(T) \sim \mathcal{N}(\mu, \sigma)$). La fonction de survie est donnée par :

$$S(t) = 1 - \Phi\left(\frac{\log(t) - \mu}{\sigma}\right) \quad h(t) = \frac{1}{S(t)\sigma t} \phi\left(\frac{\log(t) - \mu}{\sigma}\right)$$

où Φ est la fonction de répartition de la loi normale, μ la moyenne et σ l'écart-type. Ce modèle est souvent utilisé pour les temps de survie ayant une forte asymétrie, comme dans les processus où l'événement survient plus fréquemment après une certaine période de latence.

Modèle à distribution log-logistique

La **loi log-logistique** est utilisée dans des contextes où le taux de risque présente une forme non monotone, cette loi suppose que $\ln(T) = \alpha + \sigma W$ où W suit une loi logistique standard ($W \sim \mathcal{L}(\alpha, \sigma)$). Elle présente l'avantage de pouvoir identifier une date t pour laquelle le risque sera maximum. Sa fonction de survie et son risque sont donnés par :

$$S(t) = \frac{1}{1 + e^w} = \frac{1}{1 + (\lambda t)^p} \quad ; \quad h(t) = \frac{\lambda p(t)^{p-1}}{1 + \lambda t^p}$$

où $\lambda = e^{-\alpha}$ est un paramètre d'échelle et $p = 1/\sigma$ un paramètre de forme. Le modèle log-logistique est utile dans des contextes où le taux de risque augmente puis diminue, comme dans certaines maladies où la probabilité de rechute diminue après un certain point.

Modèle à distribution Gompertz-Makeham

La **loi de Gompertz-Makeham** souvent utilisée pour modéliser la mortalité adulte dans les populations développées, se caractérise par un logarithme du taux de risque linéaire avec le temps. Il est donné par :

$$h(t) = \exp(\alpha + \beta t)$$

Ce modèle est adapté pour des événements où le risque augmente avec l'âge ou le temps, comme dans les études de mortalité ou la dégradation physique.

Modèle à distribution Fisher

La **loi F généralisée** (Generalized F) est un modèle paramétrique encore plus flexible qui inclut un grand nombre de distributions comme cas particuliers, y compris les distributions log-normale, log-logistique, et Gamma généralisée. Ce modèle permet

une très large variété de formes pour les fonctions de risque et de survie, offrant ainsi un cadre unifié pour tester différentes formes paramétriques. Il est défini par :

$$Y = \log(T) = \mu + \sigma W$$

où $W = \ln(F)$ où la variable F est distribué selon une loi de Fisher. Cette loi est particulièrement utilisée pour tester diverses hypothèses sur les formes paramétriques des données. La fonction de survie est exprimée par :

$$S(t) = 1 - F\left(\frac{\log(t) - \mu}{\sigma}\right)$$

où F est la fonction de répartition de la loi de Fisher.

Modèle de Coale-McNeil

Le **modèle de Coale-McNeil** est principalement utilisé en démographie pour modéliser des événements spécifiques tels que les premières unions (par exemple, le mariage). Ce modèle repose sur une distribution de type extrême inversée, qui permet de modéliser les pics d'occurrence d'un événement à des âges précis, suivi d'une baisse progressive des occurrences. Ce modèle est particulièrement adapté aux phénomènes démographiques où les événements sont concentrés autour d'une période particulière, comme l'âge typique du mariage.

La densité associée à ce modèle est définie par :

$$g(t) = \frac{\lambda}{\Gamma(\alpha/\lambda)} e^{-\alpha(t-\theta) - e^{-\lambda(t-\theta)}}$$

où α et λ sont des paramètres de forme et θ est un paramètre de localisation qui ajuste l'âge ou le moment où l'événement est le plus probable.

Ce modèle a été dérivé à l'origine à partir de données suédoises sur les unions, mais il a depuis été généralisé à d'autres contextes démographiques. En ajustant les paramètres, il permet de bien capturer la distribution des événements qui atteignent un pic puis diminuent avec le temps.

Autres distributions

Plusieurs autres modèles paramétriques sont utilisés en analyse de survie, en fonction des caractéristiques des données et des phénomènes étudiés. Parmi les distributions utilisées pour ces autres modèles, on peut citer :

- **La distribution de Burr**, qui est une distribution à quatre paramètres utilisée pour modéliser des durées de vie complexes, avec des formes de risque variées.

- **La distribution de Pareto**, qui est une distribution à queue lourde utilisée pour modéliser des événements rares mais importants, comme les catastrophes naturelles ou les pannes critiques.
- **La distribution de Hjorth**, qui est une distribution à trois paramètres utilisée pour modéliser des durées de vie avec des formes de risque asymétriques.
- **Les splines de survie**, qui sont des modèles semi-paramétriques flexibles permettant de modéliser des fonctions de survie complexes en combinant des fonctions de base polynomiales.

Quel type de modèle paramétrique ?

- Les modèles à risques proportionnels (PH model) :

Ces modèles suppose le risque conditionné au covariables suivant :

$$h(t|X) = h_0(t)\phi(X, \beta)$$

avec $\phi(X, \beta) = \exp(X\beta)$ en général. Ainsi l'augmentation unitaire d'une variable x_j entraîne une multiplication du risque par $\exp(\beta_j)$.

Comme son nom l'indique, ce type de modèle suggèrent la proportionnalité des risques, ce qui signifie que l'effet des covariables sur le risque de défaillance est indépendant de la période de temps considérée. Evidemment, c'est une hypothèse très forte que nous devons vérifier avant de tirer des conclusions de ces modèles.

- Les modèle à Temps de Défaillance Accéléré (AFT) :

Le modèle AFT (Accelerated Failure Time) spécifie que les prédicteurs joue un role multiplicateur sur le temps de défaillance (ou additionneur sur le logarithme du temps de défaillance). Ainsi nous considérons que :

$$\ln(t) = X\beta + u \quad (=) \quad t = v \exp(X\beta) \quad ; \quad v = \exp(u) = t \exp(-X\beta)$$

et c'est la distribution du terme résiduelle u qui déterminera le type de modèle AFT utilisé. L'effet d'un prédicteur est donc d'altérer le taux auquel une observation effectue une transition, en d'autres termes un modèle AFT modifie le temps de survie, nous considérons donc le risque de base $h_0(v)$, il ne dépend donc plus uniquement du temps.

La fonction de survie et le risque s'écrivent :

$$S(t|X) = S_0(v) \quad ; \quad h(t|X) = h_0(v) \exp(X\beta)$$

On en déduit que les covariables "accélèrent" le risque de base si $\exp(-X\beta) > 1$ et le décélèrent si $\exp(-X\beta) < 1$. La fonction de survie présenté ci-dessus illustre parfaitement ce phénomène, en effet, si $\exp(-X\beta) < 1$ alors $v < t$ pour tout t , or la fonction de survie étant strictement décroissante, la probabilité de survie est augmenté en tout t par rapport à la probabilité de survie dans un modèle à risques proportionnels.

Modèle de Cox

Le modèle de Cox (D. R. COX (1972)) (ou modèle à risques proportionnels) suppose que le risque de défaillance (ou de l'événement d'intérêt) à un instant donné est proportionnel à une fonction de risque de base sur laquelle on ne fait aucune hypothèse, multipliée par une fonction exponentielle des covariables. Ce modèle présente l'avantage de ne pas avoir besoin de modéliser l'impact du temps sur le risque, il est très utile lorsque nous voulons simplement estimer l'effet des covariables sur le risque de défaillance. Cependant, il présente une certaine limite, il ne permet pas une estimation précise du temps de survie des individus qui est directement due au fait que nous ne faisons pas d'hypothèse sur le risque de base.

Sa fonction de risque est défini comme suit :

$$h(t|X) = h_0(t) \exp(X\beta)$$

La probabilité que l'individu i subisse l'événement en T conditionné au fait qu'un événement ai eu lieu en T :

$$P(T_i = t | T_i \geq t) = \frac{\exp(\beta X_i)}{\sum_{j \in R(T)} \exp(\beta X_j)}$$

Le temps n'ayant pas d'impact significatif sur le risque, on peut écrire le ratio des risques (risque relatif) comme suit :

$$\frac{h(t|X_i)}{h(t|X_j)} = \frac{\exp(X_i\beta)}{\exp(X_j\beta)} = \exp((X_i - X_j)\beta)$$

Ainsi, les coefficients β représentent l'effet des covariables sur le risque. Plus précisément, une augmentation de 1 unités de la covariable X_k multiplie le risque par $\exp(\beta)$ toutes choses étant égales par ailleurs (Colin CAMERON et Pravin K. TRIVEDI (2005)).

Le modèle est dit semi-paramétrique car il combine des éléments paramétriques et non-paramétriques :

- La partie exponentielle $\exp(X\beta)$ est paramétrique car elle dépend des coefficients β , estimés à partir des données
- La fonction de risque de base $h_0(t)$ est non paramétrique car elle n'a pas de forme fonctionnelle spécifiée et est estimée à partir des données sans faire d'hypothèses sur sa forme

L'idée de Cox est qu'aucune information ne peut être donnée sur β par les intervalles pendant lesquels aucun événement n'a eu lieu, car on peut concevoir que h_0 soit nulle dans ces intervalles, donc en ne définissant pas de fonctionnelle pour la distribution cela permet de pouvoir mieux se concentrer sur ce que nous cherchons le plus à savoir, les coefficients de régression.

Cependant ce modèle à quelques limites ; premièrement il ne peut pas être utilisé pour prédire le temps de survie d'un individu, il ne peut que donner des informations sur les effets des covariables sur le risque de défaillance. Deuxièmement, il suppose que les effets des covariables sont constants dans le temps, ce qui peut ne pas être le cas dans la réalité.

Modèle de Cox stratifié

Dans le cas où une variable qualitative ne vérifie pas l'hypothèse de hasards proportionnels, on peut considérer un modèle de Cox stratifié. Les données peuvent être naturellement divisées en sous-groupes (strates) ayant des fonctions de risque de base différentes. Pour une variable binaire donnée le risque de base est différent dans les deux strates mais les covariables X agissent de la même manière sur les deux fonctions de hasard.

$$h(t|X, Y = 0) = h_0(t) \exp(X\beta) \quad h(t|X, Y = 1) = h_1(t) \exp(X\beta)$$

Par exemple, dans une étude clinique, les patients peuvent être stratifiés par centre de traitement, par groupe d'âge, ou par type de traitement. Un modèle de Cox stratifié permet donc de prendre en compte ces différences de strates sans avoir à spécifier explicitement les fonctions de risque de base pour chaque strate. La vraisemblance partielle est calculée dans chacune des strates ; la vraisemblance totale est le produit des vraisemblances de chaque strate.

Brève présentation des outils disponibles

Sur R

Les notions théoriques fondamentales de l'analyse de survie étant défini, nous allons présenter les outils statistiques que nous allons utiliser afin de les appliquer de manière pratique. Pour ce faire, nous utiliserons le package `survival` de `R`, qui constitue une bibliothèque de référence pour l'analyse des données de survie. Ce package propose un large éventail de fonctionnalités, allant de l'estimation des fonctions de survie non paramétriques, telles que l'estimateur de Kaplan-Meier, aux modèles paramétriques et semi-paramétriques plus complexes, comme le modèle de Cox. De plus le package `flexsurv` apporte des outils supplémentaires qui nous sera utile pour l'observation des résultats

- **Censure et troncature** : Le package `survival` gère naturellement les données censurées, à droite ou à gauche, via la structure `Surv()` qui encode les informations de survie pour les analyses.
- **Estimateur de Kaplan-Meier** : Cet estimateur permet d'obtenir la fonction de survie à partir de données censurées, en tenant compte des événements observés au cours du temps. Dans `R`, l'estimateur Kaplan-Meier est implémenté via la fonction `survfit()`.
- **Tests log-rank** : Pour comparer les fonctions de survie entre deux ou plusieurs groupes, le test log-rank est implémenté avec la fonction `survdif()`. Ce test est particulièrement utile pour tester l'égalité des courbes de survie.
- **Modèle de Cox (modèle à risques proportionnels)** : Ce modèle semi-paramétrique est l'un des plus utilisés pour analyser les données de survie. Il permet d'examiner l'effet de variables explicatives sur la durée de survie, tout en faisant l'hypothèse que le ratio des risques est constant dans le temps. Le package `survival` implémente ce modèle via la fonction `coxph()`.
- **Modèles paramétriques** : Pour modéliser les durées de vie en supposant une distribution spécifique (exponentielle, Weibull, etc.), le package propose la fonction `survreg()`, qui permet de s'ajuster à différents types de distributions paramétriques.
- **Courbes de survie ajustées** : Le package permet également d'extraire et de visualiser les courbes de survie ajustées en fonction des covariables, facilitant ainsi l'interprétation des résultats des modèles.

Sur python

Les deux principaux packages utilisés en analyse de survie sont `lifelines` et `scikit-survival`.

Du Côtés de `lifelines` :

- La classe *KaplanMeierFitter* afin de d'utiliser l'estimateur de Kaplan-Meier pour la fonction de survie
- La classe *CoxPHfitter* pour cette fois-ci utiliser implémenter le modèle de Cox
- Pour effectuer le test de comparaison de courbes de survie on peut utiliser la fonction `logrank_test()` de la classe *statistics*
- Pour ce qui est de la censure, c'est via l'argument `event_observed`, commun aux différentes classes, qui prend un array Python contenant des valeurs binaires déterminant donc si l'événement a été observé.

Pour `scikit-survival` (`sksurv`) il y a par exemple :

- la classe *nonparametric* afin par exemple d'implémenter l'estimateur de Kaplan-Meier ou celui de Nelson-Aalen, via les fonctions `kaplan_meier_estimator()` et `nelson_aalen_estimator()`
- la classe *linear_model* pour utiliser le modèle de Cox, via la fonction `CoxPHSurvivalAnalysis()`.
- La classe *ensemble* permettant d'implémenter des fonctions comme `GradientBoostingSurvivalAnalysis()` cette méthode utilise des arbres de régression pour améliorer progressivement un modèle de Cox proportionnel aux risques, et `RandomSurvivalForest()` qui utilise des techniques de bootstrap et de division basées sur le log-rank pour construire des modèles

Références bibliographiques

- Colin CAMERON et Pravin K. TRIVEDI. 2005. *Microeconometrics: methods and applications*. Cambridge University Press.
- D. R. COX. 1972. « Regression Models et Life-Tables ». *Journal of the Royal Statistical Society. Series B (Methodological)*, Vol.34, No.2, 187-220.
- Dekimpe, Marnik et Dominique M. Hanssens. 2004. « Persistence Modeling for Assessing Marketing Strategy Performance ». *Assessing Marketing Strategy Performance*, C. Moorman and D. Lehmann, eds. Cambridge, MA: Marketing Science Institute.
- EsmaeiliGookeh et M. J. Tarokh. 2013. « Customer Lifetime Value Models: A Literature Survey ». *International Journal of Industrial Engineering et Production Research*, Vol. 24, No. 4.
- Fader, Peter S., Bruce G. S. Hardie, et Paul D. Berger. 2004. « Customer-Base Analysis with Discrete-Time Transaction Data ». *Unpublished working paper*.
- Fader, Peter S. et Ka Lok Lee. 2005. « RFM and CLV: Using Iso-CLV Curves for Customer Base Analysis ». *Journal of Marketing Research*, 42(November), 415-430.
- Friedman, J. H. 1991. « Multivariate Adaptive Regression Splines ». *Annals of Statistics*, 19, 1.
- Giuffrida, Giovanni, Wesley Chu, et Dominique Hanssens. 2000. « Mining Classification Rules from Datasets with Large Number of Many-Valued Attributes ». *Lecture Notes in Computer Science*, vol. 1777. Berlin: Heidelberg, 335-349.
- Gupta S., Donald R. Lehmann et Jennifer Ames Stuart. 2004. « Valuing Customers ».

- Journal of Marketing Research*, 41(1), 7-18.
- Hastie, T. J. et R. J. Tibshirani. 1990. « Generalized Additive Models ». *New York: Chapman and Hall*.
- Hogan, John E., Katherine N. Lemon, et Barak Libai. 2003. « What Is the True Value of a Lost Customer? » *Journal of Service Research*, 5(3), 196-208.
- Kaplan, E. L., et Meier, P. 1958. « Nonparametric estimation from incomplete observations. » *Journal of the American Statistical Association*, 53(282), 457-481.
- Lewis. 2005. « Incorporating Strategic Consumer Behavior into Customer Valuation ». *Journal of Marketing*, 69(4), 230-251.
- Reichheld et W. Earl Sasser Jr. 1990. « Zero Defections: Quality Comes to Services ». *Harvard Business Review*, 68(5), 105-111.
- Reinartz, Werner et V. Kumar. 2002. « The Mismanagement of Customer Loyalty ». *Harvard Business Review*, 80(7), 86-94.
- Rodríguez, G. 2010. « Parametric survival models. » *In Lecture Notes in Statistics (Vol. 200)*.
- Rust, Roland T., Tim Ambler, Gregory Carpenter, V. Kumar, et Rajendra Srivastava. 2004. « Measuring Marketing Productivity: Current Knowledge and Future Directions ». *Journal of Marketing*, 68(October), 76-89.
- Saint-Pierre, P. 2015. « Introduction à l'analyse de survie ». Université Pierre et Marie Curie.
- Sunil Gupta, Dominique Hanssens, Bruce Hardie, William Kahn, V. Kumar, Nathaniel Lin, Nalini Ravishanker et S. Sriram. 2006. « Modeling Customer Lifetime Value ». *Journal of Service Research*, Volume 9, No. 2.
- Sunil Gupta et Donald R. Lehmann. 2003. « Customers as Assets ». *Journal of Interactive Marketing*, 17 (1), 9-24.
- Taketomi, N., Yamamoto, K., Chesneau, C., et Emura, T. 2021. « Parametric Distribu-

tions for Survival and Reliability Analyses ». *A Review and Historical Sketch. Mathematics*, 9(18), 2211.

Vijay Mahajan, Eitan Muller, et Frank M. Bass. 1990. « New Product Diffusion Models in Marketing: A Review and Directions ». *Management Science*, Vol. 54.

Villanueva, Julian, Shijin Yoo, et Dominique M. Hanssens. 2006. « The Impact of Marketing-Induced vs. Word-of-Mouth Customer Acquisition on Customer Equity ». *Working paper, University of California, Los Angeles, Anderson School of Management*.

Zhang, Q. J., Dixit, A. et Friedmann, R. 2010. « Customer Loyalty and Lifetime Value: An Empirical Investigation of Consumer Packaged Goods ». *Journal Of Marketing Theory And Practice*, 18(2), 127-140.