

Mélodie Enigmatique

Décrypter le code de la popularité
musicale



Gabin SENDEL, Hugo COCHEREAU & Adam BELAMIRI

Sommaire

- I. [Introduction](#)
 - 1. [Description de la base de données](#)
 - 2. [Premières visualisations](#)
- II. [Quelques observations](#)
 - 1. [Résumé des variables quantitatives](#)
 - 2. [Répartition des featurings](#)
 - 3. [Répartition temporelle](#)
 - 4. [Popularité des morceaux](#)
 - 5. [Premiers éléments de conclusion](#)
- II. [ACP](#)
 - 1. [Présentation de l'analyse par composantes principales](#)
 - 2. [Répartition des musiques parmi les variables actives](#)
 - 3. [Matrice des corrélations](#)
 - 4. [Mise en place de l'ACP](#)
- IV. [AFC](#)
 - 1. [Présentation de l'analyse factorielle des correspondances](#)
 - 2. [Création des classes pour la variable in_spotify_charts](#)
 - 3. [Répartition de nos individus dans les variables actives](#)
 - 4. [Profils colonnes](#)
 - 5. [Profils lignes](#)
 - 6. [Mise en place de l'AFC](#)
- V. [ACM](#)
 - 1. [Etude des inerties](#)
 - 2. [Etude des variables et de leurs modalités](#)
 - 3. [Etude des individus](#)
 - 4. [Classification](#)
 - 5. [Conclusion de l'ACM et de la Classification](#)
- [Mais alors quelle est la musique idéale pour plaire aux auditeurs ?](#)

Introduction

Description de la base de données

Dans une ère où la musique n'a jamais été aussi variée, chaque artiste doit chercher l'ingrédient en plus qui lui permettra de se faire connaître par le grand public. Ainsi, le but de cette prochaine étude sera de déterminer quels facteurs pourraient rendre une musique plus populaire que les autres.

Cette étude passera par l'analyse de la base de données **Most Streamed Spotify Songs 2023** récoltée par monsieur *NIDULA ELGIRIYEWITHANA* en 2023 et laissée à libre disposition sur Kaggle.

Elle contient les titres et les noms des artistes ayant collaboré à la création des **953** musiques les plus populaires sur spotify en 2023, des informations sur plusieurs caractéristiques musicales avec divers mesures métriques de la dansabilité d'une musique, la positivité, etc..., le tempo mesuré en battement par minute (bpm), ainsi que le `mode` et la clé dominant les sonorités de la musique, la date de sortie, et les statistiques de popularité comme les classements sur plusieurs plateformes de streaming comme spotify ou encore deezer.

Nous disposons aussi du nombre d'écoutes agrégées enregistrées sur spotify et le nombre de mises en playlists de chaque musique sur apple music, spotify et deezer.

Le tableau suivant résume les **24** variables de départ de notre étude :

Variables	Description
<i>track_name</i>	Le nom de la musique
<i>artist_s_name</i>	Le nom des artistes ayant collaboré à la création de la musique
<i>artist_count</i>	Le nombre d'artistes qui ont contribué à la chanson.
<i>released_year</i>	L'année de sortie de la chanson.
<i>released_month</i>	Le mois de sortie de la chanson.
<i>released_day</i>	Le jour du mois de sortie de la chanson.
<i>in_spotify_playlists</i>	Le nombre de playlists Spotify auxquelles la chanson est incluse.
<i>in_spotify_charts</i>	La présence et le classement de la chanson sur les classements Spotify..
<i>streams</i>	Le nombre total de streams (écoutes) de la chanson sur Spotify.
<i>in_apple_playlists</i>	Le nombre de playlists Apple Music auxquelles la chanson est incluse.
<i>in_apple_charts</i>	La présence et le classement de la chanson sur les classements Apple Music.
<i>in_deezer_playlists</i>	Le nombre de playlists Deezer auxquelles la chanson est incluse.
<i>in_deezer_charts</i>	La présence et le classement de la chanson sur les classements Deezer.
<i>in_shazam_charts</i>	La présence et le classement de la chanson sur les classements Shazam.
<i>bpm</i>	Beats per minute (Battements par minute), une mesure du tempo de la chanson. Il indique à quelle vitesse la chanson est jouée.
<i>key</i>	La tonalité de la chanson, généralement exprimée en termes de notes de musique.
<i>mode</i>	Le mode de la chanson, qui peut être majeur ou mineur. Cela indique l'ambiance musicale de la chanson.
<i>danceability_percent</i>	Pourcentage indiquant à quel point la chanson est adaptée à la danse. Plus le pourcentage est élevé, plus la chanson est dansante.
<i>valence_percent</i>	Positivité du contenu musical de la chanson. Un pourcentage élevé indique une chanson joyeuse et positive.
<i>energy_percent</i>	Niveau d'énergie perçu de la chanson. Un pourcentage élevé indique une chanson énergique.
<i>acousticness_percent</i>	La quantité de son acoustique dans la chanson.
<i>instrumentalness_percent</i>	La quantité de contenu instrumental dans la chanson. Un pourcentage élevé indique une chanson principalement instrumentale avec peu de paroles.
<i>liveness_percent</i>	La présence d'éléments de performance en direct dans la chanson. Un pourcentage élevé peut indiquer des performances en direct.
<i>speechiness_percent</i>	La quantité de mots parlés dans la chanson par rapport à la musique. Un pourcentage élevé indique plus de paroles parlées que de chanté.

Premières visualisations

Voici un petit aperçu de la base de données que nous allons traiter :

track_name	artist_s_name	artist_count	released_year	released_month
<i>Seven (feat. Latto) (Explicit Ver.)</i>	Latto, Jung Kook	2	2023	7
<i>LALA</i>	Myke Towers	1	2023	3
<i>vampire</i>	Olivia Rodrigo	1	2023	6
<i>Cruel Summer</i>	Taylor Swift	1	2019	8
<i>WHERE SHE GOES</i>	Bad Bunny	1	2023	5
<i>Sprinter</i>	Dave, Central Cee	2	2023	6


Malheureusement, cette base de données comporte **145** données manquantes dont **50** pour la variable `in_shazam_charts` et **95** pour la variable `key`. De plus, un problème de codage de la variable `stream` nous pousse à nous séparer d'une musique.

En ce qui concerne le classement des musiques sur shazam, nous supposons que ces données manquantes sont dues au fait que ces musiques n'ont pas été classé, cependant, nous ne disposons pas de preuve suffisante, ainsi, il est préférable de les considérer comme une information à part entière, c'est-à-dire que l'individu concerné prend une valeur que l'on ne connaît pas à la variable considérée.

Nous remarquons que le nom des musiques constitueraient de très bons individus, cependant, il existe **10** noms de musiques identiques, on va donc considérer que les individus de notre base de données seront le nom des musiques concaténés avec le nom des artistes.

Nous disposons donc de **22** variables et de **952** individus.

Avant de démarrer notre étude descriptive, observons les **10** musiques enregistrant le plus d'écoutes sur spotify de notre base de données.



Nous identifions déjà deux musiques à part (**Shape of you** et **Blinding lights**) dans notre base de données car elles enregistrent plus de **3 milliards de streams** ce qui est très élevé par rapport aux autres musiques.

Quelques observations

Résumé des variables quantitatives

	Unique (#)	Missing (%)	Mean	SD	Min	Median	Max	
artist_count	8	0	1.6	0.9	1.0	1.0	8.0	
released_year	49	0	2018.5	10.8	1930.0	2022.0	2023.0	
released_month	12	0	6.0	3.6	1.0	5.0	12.0	
released_day	31	0	13.9	9.2	1.0	13.0	31.0	
in_spotify_playlists	827	0	4804.5	7617.5	31.0	2012.0	52898.0	
in_spotify_charts	80	0	11.9	19.2	0.0	3.0	147.0	
streams	897	0	469753138.3	519859686.3	1365184.0	271666301.0	3562543890.0	
in_apple_playlists	214	0	60.6	75.1	0.0	32.0	532.0	
in_apple_charts	165	0	50.1	49.7	0.0	35.0	275.0	
in_deezer_playlists	313	0	357.8	1121.3	0.0	40.0	12367.0	
in_deezer_charts	32	0	2.5	5.8	0.0	0.0	58.0	
in_shazam_charts	198	0	60.0	161.3	0.0	2.0	1451.0	
danceability_percent	71	0	67.2	14.6	23.0	69.0	96.0	
valence_percent	94	0	51.3	23.5	4.0	51.0	97.0	
energy_percent	80	0	64.3	16.6	9.0	66.0	97.0	
acousticness_percent	97	0	26.8	25.9	0.0	17.0	97.0	
instrumentalness_percent	39	0	1.6	8.6	0.0	0.0	91.0	
liveness_percent	67	0	18.2	13.7	3.0	12.0	97.0	

Nous pouvons déjà remarquer une donnée tout à fait aberrante car le nombre d'écoutes d'une des musiques les plus populaires de 2023 ne peut pas être égale à **2762**. Par précaution, nous préférons nous séparer de cet individu et de l'information qu'il pourrait apporter.


Répartition des featurings

nombre.d.artistes	1	2	3	4	5	6	7	8
Proportion	0.62	0.27	0.09	0.02	0.01	0.00	0.00	0.00



Comme on peut le voir sur ce tableau, la proportion des musiques en solo sont majoritaires en représentant **62%** des effectifs.

Répartition temporelle

Il est indispensable de visualiser la **répartition temporelle** des sorties des musiques avant d'émettre des affirmations sur leur contenance :




On remarque que la plupart de nos musiques sont sorties très récemment avec notamment **42%** des musiques sorties en 2022.



On peut aussi relever que les jours contenant le plus de sorties sont les premiers jour du mois avec notamment **10%** sorties pour le tout premier jour. Notons aussi que les deux mois enregistrant le plus de sorties sont les mois de **Janvier** et de **Mai** avec respectivement **14%** et **13%** sorties.

Popularité des morceaux

Un haut classement des musiques implique-t-il un nombre d'écoutes élevé ?



Ces diagrammes en boîte nous permettent de constater des résultats très différents en fonction de la plateforme concernée. En effet, on constate que *blinding lights* et *shape of you*, les deux sons les plus écoutés de notre base de données ne sont même pas classés dans les charts **shazam** et **apple music** tandis qu'elles sont classées dans les 10 premières places dans les charts **spotify** et **deezer**.

Les morceaux non-classés ont un nombre total d'écoutes plus faible pour **Spotify**, **Deezer** et **Shazam**, cependant, ce sont les morceaux classés dans le **Top 10** et classés au-delà du **top 200** qui ont le nombre d'écoutes le plus faible sur **Apple music**.

Les pistes de **Spotify** qui se classent entre le **top 51** et le **top 200** de **Spotify** ont reçu un nombre d'écoute très variable, les deux morceaux ayant le nombre de d'écoutes le plus faible et le plus élevée, et on remarque que c'est aussi cette catégorie qui a l'écart interquartile le plus large.

Premiers éléments de conclusion

- Les musiques les plus populaire de **Spotify** en 2023 sont pour la plupart très récentes, ce qui traduirait un goût pour la nouveauté des auditeurs spotify ;
- Autres découvertes intéressantes, il ne faut pas négliger le fait que beaucoup de ces musiques soient sorti en début de mois, cela pourrait traduire des stratégies de marketing de ces artistes qui décideraient de sortir leurs musiques les plus susceptibles d'attirer un grand nombre d'auditeurs en début de mois ;
- Enfin, ces statistiques descriptives nous ont démontré que les résultats que nous obtiendrons lors de nos prochaines analyses devront être interpréter avec précaution étant donné que la popularité des différents morceaux n'est pas la même en fonction de la plateforme étudiée.

ACP

Présentation de l'analyse par composantes principales

Pour mener une analyse en composantes principales (ACP) visant à comprendre les facteurs de succès d'une musique, nous nous appuierons sur des variables clés qui reflètent divers aspects de la popularité et des caractéristiques musicales. Notre objectif est d'identifier ce qui permet à une musique d'avoir un meilleur succès que les autres.

Nous explorerons différentes variables tel que l'énergie d'une chanson, une mesure de son dynamisme et de son intensité, qui peut captiver l'auditeur et favoriser la répétition des écoutes. La valence, reflétant la positivité et la joie véhiculée par la musique, qui joue également un rôle crucial dans l'attrait émotionnel auprès du public.


La présence dans les playlists, tant sur Spotify (`in_spotify_playlists`) que sur Deezer (`in_deezer_playlists`), indique une popularité et une exposition accrue. Cela peut non seulement augmenter le nombre de streams mais aussi renforcer la reconnaissance d'une chanson auprès d'un large public.

Le nombre de streams lui-même est un indicateur direct de popularité, révélant à quel point une chanson est fréquemment écoutée. Une analyse des tendances dans les streams peut nous aider à comprendre les dynamiques d'écoute et la fidélité des auditeurs.

La danseabilité d'une chanson reflète sa capacité à inciter à la danse, un facteur potentiellement important dans des contextes sociaux ou festifs. Enfin, l'acoustique donne une idée de la texture sonore et de l'authenticité perçue d'une chanson, influençant son attrait auprès des auditeurs à la recherche de qualités musicales plus naturelles ou organiques.


À travers cette ACP, nous chercherons à comprendre comment ces variables interagissent et contribuent ensemble au succès d'une chanson. En examinant les tendances et les corrélations, nous pourrions identifier les caractéristiques clés qui définissent les chansons à succès dans l'industrie musicale moderne.

Répartition des musiques parmi les variables actives



Nous remarquons que la plupart des musiques contiennent peu de mots parlés, sont très peu instrumentales et semblent enregistrées en studio la plupart du temps. On notera aussi que l'on dispose de musiques plutôt énergiques et dansantes avec un bpm raisonnable. Enfin on observe aussi que les morceaux sont pour la plupart peu acoustiques.

Matrice des corrélations




On observe grâce à cette matrice des corrélations que les variables `energy_percent`, `danceability_percent` et `valence_percent` sont corrélées positivement et que ces même variables sont corrélées négativement à `acousticness_percent`.

Ensuite, on notera que la présence dans les playlists de chaque plateformes est corrélée positivement avec le nombre d'écoutes des musiques sur spotify et que ces même variables sont corrélées négativement avec l'année de sortie du morceau. Cela indique donc que les musiques très récentes auraient en moyenne moins de streams.

Enfin, il est aussi intéressant de constater que le nombre de mots parlés dans un morceau et la dansabilité sont corrélées négativement avec sa popularité.

Mise en place de l'ACP

Inertie des axes




	comp 1	comp 2	comp 3	comp 4	comp 5	comp 6	comp 7	comp 8	comp 9	comp 10	comp 11	comp 12	comp 13	comp 14	comp 15
eigenvalue	3.32	2.12	1.24	1.14	1.06	1.03	0.93	0.90	0.82	0.78	0.55	0.51	0.30	0.20	0.10
percentage of variance	22.11	14.12	8.28	7.58	7.05	6.90	6.21	6.03	5.45	5.22	3.66	3.39	2.01	1.32	0.65
cumulative percentage of variance	22.11	36.23	44.52	52.10	59.15	66.05	72.26	78.29	83.75	88.96	92.62	96.01	98.03	99.35	100.00

Lors de la mise en place de l'ACP nous avons d'abord décidé de conserver seulement 3 axes en nous référant à la methode du coude mais finalement nous en avons conservé deux puisque nous avons remarqué que le troisieme axe ne nous fournissait pas d'information pertinente. Sachant qu'avec ces deux axes, on capte quand même **36.23%** de l'inertie totale .

Etude des variables


Nuage des variables



Ce cercle des corrélations n'affiche que les variables dont la qualité de représentation sur le plan (1,2) est supérieur à 0.2, on peut noter plusieurs choses :

- Les variables `energy`, `valence` et `danceability` semblent être positivement corrélées car elles pointent dans la même direction générale. Cela signifie que les chansons perçues comme énergiques sont également susceptibles d'être perçues comme entraînantes (dansantes) et avec une valence positive (c'est-à-dire plus joyeuses).
- En revanche, `acousticness` semble être en corrélation négative avec `energy` et `valence`, comme en témoignent les flèches pointant dans des directions presque opposées. Cela indique que les chansons avec une forte composante acoustique sont souvent moins énergiques et moins joyeuses.
- Ensuite on remarque que les variables `streams`, `in_apple_playlists`, et `in_deezer_playlists` sont groupées et orientées vers la droite du cercle de corrélation, indiquant une corrélation positive entre elles. Les chansons qui sont fréquemment streamées tendent également à apparaître dans de nombreuses playlists, ce qui est plutôt logique. De plus, ces mêmes variables pointent dans une direction opposée à la variable `released_year` ce qui indique que les musiques plus récentes sont moins présentes dans les playlists et ont moins de streams sur spotify.
- Enfin, il est très important de noter que l'orthogonalité des variables désignant la popularité avec les variables désignant les caractéristiques musicales mettent en lumière une certaine indépendance entre la popularité des musiques et leurs caractéristiques musicales.

Contributions



`in_spotify_playlists` a la contribution la plus élevée (27.03%) sur le 1^{er} axe, ce qui suggère que la présence d'une chanson dans les playlists Spotify est un facteur significatif dans la variabilité des données sur cet axe.

`streams`, `in_deezer_playlists` et `in_apple_playlists` sont également des contributeurs majeurs avec des contributions de respectivement 23.33%, 19.94% et 19.58%, ce qui n'est pas surprenant car le nombre d'écoutes en streaming est un indicateur direct de la popularité d'une chanson.

Les autres variables concernant les caractéristiques musicales, comme `danceability_percent` et `acousticness_percent`, contribuent très peu à la construction de cet axe.

La variable `energy_percent` est la variable prédominante sur le 2^{ème} axe avec 27.09% de contribution, indiquant que l'énergie d'une chanson joue un rôle central dans la différenciation des chansons sur cet axe. Cela pourrait signifier que comme évoqué lors de l'analyse du nuages des variables, les chansons avec une énergie élevée se distinguent des autres, possiblement en raison de leur aptitude à engager l'auditeur et à créer une expérience d'écoute dynamique et stimulante.


Les variables suivantes semblent avoir des contributions moins importantes mais néanmoins significatives. Si elles suivent l'ordre de grandeur de contribution décroissante, cela pourrait inclure des aspects tels que `acousticness_percent`, `danceability_percent` et `valence_percent` qui ont des contributions de respectivement 21.01%, 18.95% et 17.95%. Ces caractéristiques, lorsqu'elles sont associées à une énergie élevée, peuvent renforcer l'attrait d'une chanson, la rendant plus apte à capter et à maintenir l'attention des auditeurs, et par conséquent à augmenter sa popularité et son succès.

Conclusion sur les axes

L'étude des variables permet de constater que l'axe 1 désigne la popularité des musiques en terme de nombre d'écoutes et de présence dans les playlists, tandis que l'axe 2 désigne la quantité d'énergie dégagée par une musique.

Etude des individus

Nuage des individus



Le nuage des individus permet de démontrer que les musiques les plus streamées de notre base de données ne sont pas essentiellement les mieux classées dans les charts spotify, en effet, les musiques positionnées aux plus grandes valeurs de l'axe 1 ne sont pas toutes classées dans le top 5, de plus, nous ne distinguons pas de relation évidente entre une caractéristique musicale et le nombre d'écoutes sur spotify.

Contributions

Quels sont les musiques contribuant le plus à la construction de l'axe 1

	Musique	Contributions (en %)
623	Smells Like Teen Spirit - Remastered 2021 _ Nirvana	3.48
56	Blinking Lights _ The Weeknd	3
716	Bohemian Rhapsody - Remastered 2011 _ Queen	2.22
719	Wake Me Up - Radio Edit _ Avicii	2.16
629	Mr. Brightside _ The Killers	1.99
870	Sweet Child O' Mine _ Guns N' Roses	1.85
163	Enchanted _ Taylor Swift	1.74
756	Get Lucky - Radio Edit _ Pharrell Williams, Nile Rodgers, Daft Punk	1.69
619	Dance Monkey _ Tones and I	1.49
180	Night Changes _ One Direction	1.46

Quels sont les musiques contribuant le plus à la construction de l'axe 2

	Musique	Contributions (en %)
461	Wonderful Christmastime - Edited Version / Remastered 2011 _ Paul McCartney	1.28
696	Something In The Way - Remastered 2021 _ Nirvana	1.26
18	What Was I Made For? [From The Motion Picture "Barbie"] _ Billie Eilish	1.03
939	Sweet Nothing _ Taylor Swift	0.98
470	Driving Home for Christmas - 2019 Remaster _ Chris Rea	0.97
388	STAR WALKIN' (League of Legends Worlds Anthem) _ Lil Nas X	0.96

	Musique	Contributions (en %)
690	Forever _ Labrinth	0.96
948	Bigger Than The Whole Sky _ Taylor Swift	0.91
908	Static _ Steve Lacy	0.91
800	Crown _ Kendrick Lamar	0.84

On remarque que la chanson Smell Like Teen Spirit est la musique qui contribue le plus à l'axe 1. La musique Blinding Lights de The Weeknd contribue aussi fortement à l'axe 1. Ce qui est cohérent avec la signification de l'axe 1 puisque Blinding Lights est la musique la plus écoutée de notre base de données.

En revanche, pour l'axe 2 c'est davantage hétérogène, il n'y a pas de chanson qui contribuent significativement plus qu'une autre.

Conclusion de l'ACP

L'analyse par composantes principales ne nous aura pas permis de déterminer un lien entre les caractéristiques musicales et la popularité d'une musique en terme d'écoutes et de présence dans les playlists, cependant, nous avons pu observer qu'il n'y a pas de lien évident entre le nombre d'écoutes d'une musique et son classement dans les charts de la plateforme spotify, il sera donc intéressant d'effectuer une nouvelle étude en modifiant notre conception de la popularité d'une musique.

AFC

Présentation de l'analyse factorielle des correspondances

Pour l'analyse factorielle des correspondances, il nous a fallu trouver deux variables qualitatives. Étant donné que dans notre problématique, nous cherchons ce qui permettrait à une musique d'obtenir une meilleure popularité que les autres, il nous fallait trouver une variable représentant ce fameux succès.

Nous avons d'abord pensé à la variable `streams`, une variable quantitative qui représente la quantité d'écoute d'une musique sur Spotify, que nous voulions séparer en classes. Le premier problème de cette variable était son étendue de **3702529890**. Cela vient de l'écart entre le nombre de streams de la musique la moins écoutée (1365184) et la musique la plus écoutée (3703895074). On passe de quelques millions de streams à plus de 3 milliards pour les plus écoutées. Avoir de tels chiffres rend la variable difficile à utiliser et à interpréter.

Cela a aussi influencé les classes que nous avons essayé de créer, avec plus de la moitié des individus présents dans une seule classe et quelques individus dans les classes représentant les musiques avec le plus de streams. Nous avons alors essayé de la normaliser pour avoir des nombres compris entre 0 et 100, toujours avec l'idée que les musiques proches de 100 sont les plus écoutées. Mais cela ne réglait pas le problème des classes étant donné que cette méthode est très sensible aux valeurs extrêmes, avec beaucoup d'individus présents dans une seule classe. Nous avons alors fait le choix de ne pas travailler avec la variable `streams`.

Nous nous sommes alors tournés vers la variable `in_spotify_charts`. Cette variable représente le classement des musiques de Spotify. Les valeurs de cette variable vont de **1** à **147**, avec l'idée que plus une musique est proche de 1, meilleur est son classement et donc plus son succès est important. Nous considérerons que les musiques où la variable vaut 0 ne sont pas classées.


Création des classes pour la variable `in_spotify_charts`

Nous avons créé les classes suivantes :

Valeur de la variable	[1;5]	[6;20]	[21;50]	[51;200]	pas classé
Classe associée	Top 5	Top 20	Top 50	> 50	0

Maintenant que nous avons une première variable qui représente le succès, nous en cherchons une deuxième pour le caractériser. Nous décidons alors de prendre la variable `saison`, préalablement créée en regroupant par classe les mois de l'année. Notre idée est de voir si la saison pendant laquelle une musique est sortie a une influence sur son succès.

Répartition de nos individus dans les variables actives



On remarque que la saison du printemps est celle qui regroupe le plus d'individus (**46**). De plus, nous remarquons que **280** musiques ne sont pas classées sur spotify.

Regardons les effectifs croisés

	automne	été	hiver	printemps
Top 5	27	26	37	51
Top 20	49	43	52	64
Top 50	19	44	47	42
> 50	8	15	13	10
pas classé	106	66	119	113

Ensuite, nous allons réaliser un test du χ^2 afin de tester l'indépendance entre les deux variables

Résultats du test

X-squared	28.3452
df	12.0000
p.value	0.0049

Le test du χ^2 nous ressort une p-value de **0.0049** donc nous rejetons l'hypothèse d'indépendance entre la saison de sortie d'une musique et son classement sur spotify.

Afin de vérifier la validité du test et de ses résultats, nous allons observer les effectifs théoriques ainsi que les contributions au χ^2

	<i>Effectifs théoriques</i>			
	automne	été	hiver	printemps
<i>Top 5</i>	30.987	28.763	39.735	41.514
<i>Top 20</i>	45.712	42.431	58.616	61.241
<i>Top 50</i>	33.405	31.007	42.835	44.753
<i>> 50</i>	10.109	9.384	12.963	13.544
<i>pas classé</i>	88.787	82.414	113.851	118.948

Tous les effectifs théoriques sont supérieurs à 5, ce qui est en faveur de la validité du test.

	<i>Observons les contributions au χ^2</i>				
	automne	été	hiver	printemps	Total
<i>Top 5</i>	1.81	0.94	0.66	7.65	11.06
<i>Top 20</i>	0.83	0.03	2.63	0.44	3.93
<i>Top 50</i>	21.91	19.21	1.43	0.60	43.15
<i>> 50</i>	1.55	11.86	0.00	3.27	16.68
<i>pas classé</i>	11.77	11.53	0.82	1.05	25.18
<i>Total</i>	37.89	43.56	5.55	13.00	100.00

Aucune contribution ne dépasse les 50%, nous n'avons pas de modalités qui contribuent de manière exagérée par rapport aux autres. Nous pouvons quand même mettre en avant une forte contribution des saisons automne et été, ainsi que des modalités *Top 50* et *pas classé*.


Nous allons à présent analyser la répartition des profils lignes et colonnes afin d'établir nos premières hypothèses concernant le lien existant entre ces deux variables avant de les illustrer lors d'une AFC.

Profils colonnes

Notre problématique faisant référence à ce qui pourrait caractériser le succès d'une musique, nous allons, au cours de nos observations, porter une plus grande attention à la modalité *Top 5*.

	automne	été	hiver	printemps	Profil moyen
<i>Top 5</i>	12.92	13.40	13.81	18.21	14.83
<i>Top 20</i>	23.44	22.16	19.40	22.86	21.87
<i>Top 50</i>	9.09	22.68	17.54	15.00	15.98
<i>> 50</i>	3.83	7.73	4.85	3.57	4.84
<i>pas classé</i>	50.72	34.02	44.40	40.36	42.48
<i>Total</i>	100.00	100.00	100.00	100.00	100.00

Répartition des profils colonnes




En regardant les profils colonnes (donc les saisons), nous remarquons que c'est dans la modalité printemps que *Top 5* possède la plus grosse proportion (**18.21%**)

Profils lignes

	automne	été	hiver	printemps	Total
<i>Top 5</i>	19.15	18.44	26.24	36.17	100
<i>Top 20</i>	23.56	20.67	25.00	30.77	100
<i>Top 50</i>	12.50	28.95	30.92	27.63	100
<i>> 50</i>	17.39	32.61	28.26	21.74	100
<i>pas classé</i>	26.24	16.34	29.46	27.97	100
<i>Profil moyen</i>	21.98	20.40	28.18	29.44	100

Répartition des profils lignes




Lorsque nous passons maintenant aux profils lignes (c'est-à-dire les classements) et que nous regardons la ligne correspondante à *Top 5* et *Top 20*, nous observons que c'est *printemps* qui possède la plus grosse proportion (**36.17% et 30.77%**)

Nos premières observations nous laissent penser qu'il pourrait y avoir un lien entre le fait de sortir une musique au printemps et d'avoir une musique bien classée.

Mise en place de l'AFC

Inertie et part de variance des axes




Nous observons que le 1er axe de notre AFC rassemble à lui seul **76.68%** de l'information.

	F1	F2	F3
Parts de Variance	76.68	17.64	5.68
Parts cumulées	76.68	94.32	100.00

Pour notre étude, nous décidons alors de garder les deux premiers axes, ce qui nous permet de conserver **94.32%** de l'information.

Nuage des modalités




Pour ce qui est de la variable classement, on remarque que la modalité `pas classé` semble s'opposer aux modalités `Top 50` et `> 50` le long de l'axe 1. La modalité `Top 5` qui nous intéresse le plus semble, quant à elle, contribuer à la construction de l'axe 2.

Pour la variable saison, les modalités `automne` et `été` semblent s'opposer le long de l'axe 1. La modalité `printemps` semble contribuer à l'axe 2.

Vu les qualités de représentation de `Top 20` et `hiver`, nous préférons ne pas les mettre en avant dans notre analyse.

Ce qui nous intéresse le plus, c'est que les modalités `printemps` et `Top 5` semblent toutes les deux contribuer au même axe. Les deux modalités semblent s'associer, ce qui renforce nos premières hypothèses, nous pouvons faire la même remarque en ce qui concerne les modalités `pas classée` et `automne`.

Etude du 1er axe




	été	automne	printemps	hiver
Contributions	54.2	44.5	1.0	0.4
Contributions cumulées	54.2	98.6	99.6	100.0

	Top 50	pas classé	> 50	Top 20	Top 5
Contributions	55.1	28	16.4	0.6	0
Contributions cumulées	55.1	83	99.4	100.0	100

Les graphiques et tableaux précédents renforcent les hypothèses émises lors de l’observation du nuage des modalités.

On remarque que **été** et **automne** contribuent fortement à la construction du premier axe (respectivement **54.2%** et **44.5%**). Tout comme **Top 50 (55.1%)**, **> 50 (16.4%)** et **pas classé (28%)**

Etude du second axe



	printemps	automne	hiver	été
Contributions	69.5	15.6	9.9	4.9
Contributions cumulées	69.5	85.2	95.1	100.0

	Top 5	> 50	pas classé	Top 20	Top 50
Contributions	62.1	18.0	17.3	2.5	0.1
Contributions cumulées	62.1	80.1	97.4	99.9	100.0

De même pour le deuxième axe, comme vu précédemment, ce sont les modalités `printemps` et `Top 5` qui contribuent le plus à la construction de l'axe 2, avec une contribution respective de **69.5%** et de **62.1%**

Conclusion de l'AFC

Les résultats de cette AFC semblent mettre en avant une association entre les modalités `Top 5` et `printemps`. Nous serions alors tentés d'admettre que les musiques qui sortent à la saison printemps ont tendance à figurer parmi les musiques les mieux classées sur Spotify. On pourrait en conclure que les auditeurs ont tendance à écouter plus de musiques lors de la période printanière, cependant, il est difficile de déterminer si cette association est directe, car les musiques qui sortent au printemps peuvent posséder des caractéristiques qui favoriseraient leur présence dans le haut des classements, ce qui amenuiserait les implications des résultats de notre AFC. Ainsi, nous tenterons alors de déterminer ces différentes caractéristiques lors d'une analyse par composantes multiples.

ACM


Avant de présenter les différents résultats de l'analyse par composantes multiples, il est nécessaire d'avoir en tête plusieurs informations cruciales :

- Cette base de données contient les morceaux les plus populaires de spotify en 2023, cela signifie que toutes les musiques présentées présentent des caractéristiques capables de plaire au grand public, cependant, l'objectif de cette ACM sera de déterminer à quoi ressemble la population dans sa globalité tout en examinant ses différences avec les musiques les plus hétérogènes.
- Comme démontrer lors des statistiques descriptives, ces résultats ne pourront pas être généralisés pour toutes les plateformes.

Nous allons effectuer cette ACM en portant une attention particulière aux variables suivantes :

- `danceability`, `valence`, `energy`, `acousticness_percent`, `speechiness`, `liveness`, `instrumentalness` et `bpm_normx100` dérivées des variables quantitatives du même nom que l'on a découpé en 4 classes, plus l'indice est grand et plus la caractéristique prend de l'ampleur sur le morceau ;
- `tonalité` : crée à partir de la variable `key` qui prend les modalités `registre_?` pour les valeurs manquantes, `registre_aigu` pour les clés de sonorités plutôt aigu, `registre_normal` et `registre_grave`, elle sera utilisée comme variable supplémentaire si elle apporte des informations pertinentes ;
- Les classements des morceaux sur chaque plateforme découpés en classe que l'on utilisera comme variables supplémentaires ;
- La variable `saison` sera elle aussi à suivre au cours de cette ACM. Elle sera intégrée comme variable supplémentaire. En effet, l'un des objectifs de cette partie de l'étude sera déterminer un potentiel lien entre des caractéristiques musicales d'une musique et sa saison de sortie afin de vérifier si la corrélation illustrée lors d'AFC serait un lien plutôt direct ou indirect ;
- Toutes les autres variables seront utilisées comme variables supplémentaires si elles sont susceptibles de nous apporter des informations pertinentes.


Etude des inerties



Ce graphique nous permet de représenter l'inertie portée par chaque axe factoriel. En nous basant sur le critère du coude, cette visualisation nous incite à sélectionner les 2 premiers axes car on observe une décroissance de l'inertie stable jusqu'au 2nd axe suivi d'une très nette accélération de la décroissance passant de **14.72%** d'inertie représenté sur les 2 premiers axes à **8.99%** représenté sur le premier axe.

Etude des variables et de leurs modalités

Représentation des variables et de leurs modalités



Ce nuage des modalités nous permet de remarquer plusieurs chose sur la signification des deux premiers axes :

Tout d'abord, on remarque que les variables indiquant les **caractéristiques musicales** (*danceability*, *valence*, *energy*) sont ordonnées sur l'axe 1 s'étalant de 1 à 4 en partant de la droite, on peut faire la même remarque mais dans le sens contraire pour l'indice de **sonorité acoustique**. Ces deux remarques laissent penser à un effet Guttman. Nos impressions sur l'axe 1 sont confirmées par la corrélation positive entre les variables *energy_percent*, *danceability_percent* et *valence_percent* et une corrélation négative entre ces mêmes variables et la variable *acousticness_percent* ainsi qu'à l'axe 1.


Ensuite, on remarque que l'indice relevant du nombre de mots parlés dans un morceau semble s'ordonner sur l'axe 2 s'étalant de 1 à 2 de haut en bas, cependant les qualités de représentation de ces modalités sont très faibles, il nous faut donc davantage d'informations afin de confirmer cette impression. On identifie aussi une faible corrélation négative entre l'axe 2 et les variables *rythme_bpm* et *speechiness_percent* ainsi qu'une faible corrélation positive avec la variable *liveness_percent*.

La proximité entre différentes modalités et le barycentre de ce nuage laisserait supposer que la pseudo-musique moyenne serait une musique peu acoustique, dansante, énergiques et positive.

L'information la plus intéressante du nuage des modalités est la rareté apparente des modalités `energy_1`, `acousticness_4` car cela sous-entend que dans notre base de données, il y a peu de musiques avec une faible énergie et de musiques où les sonorités sont dominées par les éléments acoustiques.


On admettra aussi qu'aucune des modalités de nos variables qualitatives et notamment le classement des musiques sur les différentes plateformes ne semblent très bien représentés sur ce plan qui ne représente que les modalités dont la qualité de représentation est supérieure à **0.15**.

Enfin, il ne faut pas oublier que les qualités de représentation de nos modalités ne dépassent pas **0.5** sur ce nuage, il est donc nécessaire d'utiliser d'autres outils afin de confirmer nos impressions, cependant, les modalités citées précédemment ont une qualité de représentation suffisamment grande pour que l'on s'intéresse à elles.




Le carré du rapport de corrélation des variables actives appuie nos observations du nuage des modalités, on pourra aussi relever que l'axe 2 apporte des informations sur la variable `energy`.

Contribution des variables




Les modalités contribuant le plus à l'axe 1 sont celles concernant l'énergie d'une musique, sa dansabilité et sa sonorité acoustique avec **47.82%** de contribution des modalités `acoustictness_4` (**18.77%** à elle seule), `danceability_2`, et `energy_2`.



Les modalités contribuant le plus à l'axe 2 sont issues des variables `energy`, `speechiness` et `rythme_bpm` avec **32.44%** de contribution cumulées des modalités `energy_1` (**11.53%** à elle seule), `speechiness_2` et `rythme_bpm_2`.

Etude des individus

Représentation des individus



On remarque un groupe de musiques se concentrant plutôt autour du barycentre, et plusieurs petits groupes se détachant plus ou moins du côté des valeurs positives de l’axe 1. Dans l’ensemble, la répartition des musiques semblent suivre les modalités et on distingue un groupe de musique à plus fortes contributions. On peut aussi relever que quelques morceaux se démarquent de part leur position sur l’axe 2.

Musiques aux extrémités des axes

Musique	top_spotify	top_apple	top_deezer	rythme_bpm	danceability	valence	energy	acousticness	instrumentalness	liveness	speechiness
BABY HELLO Rauw Alejandro, Bizarrap	Top 50	>50	Top 5	2	4	4	4	1	1	2	1
Something In The Way - Remastered 2021 Nirvana	pas classé	Top 50	pas classé	2	2	1	1	3	2	1	1
Something In The Way - Remastered 2021 Nirvana	pas classé	Top 50	pas classé	2	2	1	1	3	2	1	1
METAMORPHOSIS INTERWORLD	Top 50	>50	pas classé	4	3	1	3	2	4	1	1

Le tableau ci-dessus met en valeurs 4 individus, chacun représentant une extrémité d’un axe :

- 1 : Gauche axe 1
- 2 : Droite axe 1
- 3 : Haut axe 2
- 4 : Bas axe 2

Les valeurs prises par les individus tendent à confirmer les hypothèses émises pour l’axe 1 et 2.

Contribution des individus

Combien de musiques pour arriver à 50% de contribution ?

dim 1	dim 2
58	89

Il faut 58 musiques pour avoir **50%** de contribution à la construction de l'axe 1, cela pourrait signifier qu'un groupe de musiques a une forte contribution par rapport aux restes de la population étudiée. En ce qui concerne l'axe 2, cela nécessite 89 musiques donc l'information apporté par cet axe devrait être plus générale.

Conclusion sur les axes

La visualisation des nuages et des contributions des modalités et des individus permet de confirmer certaines hypothèses concernant les axes 1 et 2 :


L'axe 1 désigne l'énergie émise par une musique, plus la valeur prise sur l'axe est haute, moins la musique est énergétique et plus elle est acoustique ;

L'axe 2 a une légère corrélation avec le nombre de bpm d'une musique.

Classification


Lors de cette section, nous allons effectuer une classification ascendante hiérarchique à partir de l'ACM vu précédemment, et essayer d'identifier des groupes d'individu. Avant d'observer les résultats de la classification, observons la répartition des musiques parmi les variables qui nous intéressent :

Répartition des musiques




La répartition des musiques nous indiquent qu'une très grande partie des musiques prennent les modalités `instrumentalness_1` et `speechiness_1` ce qu'il faudra prendre en compte lors de l'évaluation des résultats de la classification.

Premières visualisations des clusters



La visualisation du dendrogramme ainsi que le graphique des gains d'inertie inter-cluster pour chaque cluster additionnel nous incite à choisir 5 clusters afin d'obtenir une partition maximisant l'inertie inter-cluster, en effet le passage de 5 à 4 clusters nous ferait perdre beaucoup d'inertie inter-cluster.



Cette première visualisation nous permet de remarquer que le plus gros des clusters est le 1^{er} cluster qui regroupe des musiques se positionnant plutôt au centre de plan, on peut supposer que les 4 autres clusters mettent en scène des musiques très spéciales par rapport au reste de la base de données.

Pour la suite de cette section, nous n'allons présenter que les résultats que nous jugeons utiles pour le développement de l'étude.

Résultats de la classifications

Tout d'abord, concentrons-nous sur la répartition des modalités au sein de chaque cluster afin de déterminer les populations représentées par les clusters.

Variables

Catégories représentant le mieux le premier cluster					
	Cla/Mod	Mod/Cla	Global	p.value	v.test
instrumentalness=instrumentalness_1	91.2	100.0	97.9	0.0000	9.38
rythme_bpm=rythme_bpm_2	97.0	45.9	42.3	0.0000	7.03
danceability=danceability_4	97.2	37.2	34.2	0.0000	6.23
rythme_bpm=rythme_bpm_1	95.3	28.5	26.7	0.0001	3.83
acousticness=acousticness_1	91.8	59.7	58.0	0.0029	2.98
rythme_bpm=rythme_bpm_3	93.9	25.6	24.3	0.0062	2.74
speechiness=speechiness_1	90.2	89.5	88.6	0.0216	2.30
released_month_char=décembre	95.9	8.4	7.8	0.0403	2.05
key=A	81.1	7.1	7.8	0.0283	-2.19
valence=valence_1	83.6	15.7	16.7	0.0168	-2.39
speechiness=speechiness_3	0.0	0.0	0.2	0.0114	-2.53
danceability=danceability_1	0.0	0.0	0.2	0.0114	-2.53
acousticness=acousticness_4	77.5	7.3	8.4	0.0014	-3.19
instrumentalness=instrumentalness_4	0.0	0.0	0.3	0.0012	-3.24
instrumentalness=instrumentalness_3	0.0	0.0	0.7	0.0000	-5.27
liveness=liveness_4	0.0	0.0	0.8	0.0000	-5.68
danceability=danceability_2	71.1	10.1	12.7	0.0000	-6.05
instrumentalness=instrumentalness_2	0.0	0.0	1.1	0.0000	-6.42
energy=energy_1	0.0	0.0	1.4	0.0000	-7.42
rythme_bpm=rythme_bpm_4	0.0	0.0	6.7	0.0000	-18.09

La répartition des modalités dans le 1^{er} cluster indique qu'une grosse partie des musiques les plus populaires de 2023 sur spotify sont des musiques énergiques, dansantes et peu acoustiques, de plus elles auraient un nombre de bpm plutôt raisonnable. Il est cependant difficile d'émettre des affirmations sur ce cluster car il contient beaucoup de morceaux très différents sur plusieurs aspects. On relèvera tout de même qu'aucune musique indicée 1 sur les variables `energy` et `danceability` ne font parties de ce cluster.

Catégories représentant le mieux le second cluster

	Cla/Mod	Mod/Cla	Global	p.value	v.test
rythme_bpm=rythme_bpm_4	93.8	96.8	6.7	0.0000	19.84
instrumentalness=instrumentalness_4	100.0	4.8	0.3	0.0003	3.65
speechiness=speechiness_2	15.1	25.8	11.1	0.0008	3.34
danceability=danceability_2	13.2	25.8	12.7	0.0039	2.89
danceability=danceability_3	8.3	67.7	52.9	0.0152	2.43
released_month_char=octobre	1.4	1.6	7.7	0.0448	-2.01
released_month_char=décembre	1.4	1.6	7.8	0.0421	-2.03
speechiness=speechiness_1	5.5	74.2	88.6	0.0010	-3.28
rythme_bpm=rythme_bpm_3	0.4	1.6	24.3	0.0000	-5.07
danceability=danceability_4	1.2	6.5	34.2	0.0000	-5.27
rythme_bpm=rythme_bpm_1	0.4	1.6	26.7	0.0000	-5.44
rythme_bpm=rythme_bpm_2	0.0	0.0	42.3	0.0000	-8.16

Ce second cluster contient les musiques très rythmées en témoigne le fait que **96.8%** des musiques de ce cluster prennent la modalité `rythme_bpm_4`.

Catégories représentant le mieux le troisième cluster

	Cla/Mod	Mod/Cla	Global	p.value	v.test
liveness=liveness_4	100.0	80	0.8	0.0000	8.72
danceability=danceability_1	100.0	20	0.2	0.0001	3.89
acousticness=acousticness_1	0.4	20	58.0	0.0190	-2.35
danceability=danceability_4	0.0	0	34.2	0.0149	-2.43
liveness=liveness_1	0.1	10	75.5	0.0000	-4.23

Le troisième cluster quant à lui regroupe les musiques très peu dansantes et les musiques composées en direct plutôt qu'en studio.

Catégories représentant le mieux le quatrième cluster

	Cla/Mod	Mod/Cla	Global	p.value	v.test
instrumentalness=instrumentalness_3	100.0	77.8	0.7	0.0000	8.19
speechiness=speechiness_3	100.0	22.2	0.2	0.0001	3.95
key=A	5.4	44.4	7.8	0.0034	2.93
released_month_char=juin	3.5	33.3	9.0	0.0457	2.00
instrumentalness=instrumentalness_1	0.2	22.2	97.9	0.0000	-6.71

Le 4^{ème} cluster contient les musiques où beaucoup de mots sont parlés plutôt que chantés.

Catégories représentant le mieux le cinquième cluster

	Cla/Mod	Mod/Cla	Global	p.value	v.test
energy=energy_1	100.0	61.9	1.4	0.0000	10.17
instrumentalness=instrumentalness_2	100.0	47.6	1.1	0.0000	8.75
danceability=danceability_2	12.4	71.4	12.7	0.0000	6.22
acousticness=acousticness_4	15.0	57.1	8.4	0.0000	5.74
valence=valence_1	6.9	52.4	16.7	0.0002	3.74
top_spotify=top_spotify_pas classé	4.2	81.0	42.5	0.0004	3.56
feat=non	3.2	90.5	61.6	0.0039	2.89
tonalite=registre ?	6.3	28.6	10.0	0.0162	2.40
key=key.NA	6.3	28.6	10.0	0.0162	2.40
top_shazam=top_shazam_pas classé	3.8	61.9	36.1	0.0172	2.38
acousticness=acousticness_2	0.5	4.8	21.6	0.0455	-2.00
energy=energy_4	0.7	9.5	29.7	0.0336	-2.12
top_spotify=top_spotify_Top 5	0.0	0.0	14.8	0.0331	-2.13
valence=valence_4	0.0	0.0	19.7	0.0095	-2.59
danceability=danceability_3	1.0	23.8	52.9	0.0075	-2.67
feat=oui	0.5	9.5	38.4	0.0039	-2.89
danceability=danceability_4	0.3	4.8	34.2	0.0018	-3.12
acousticness=acousticness_1	0.9	23.8	58.0	0.0017	-3.15
energy=energy_3	0.4	9.5	51.1	0.0001	-3.98
instrumentalness=instrumentalness_1	1.2	52.4	97.9	0.0000	-7.27

Le 5^{ème} a le mérite de nous proposer une relation entre une caractéristique musicale et le classement du morceau dans les charts spotify, en effet, toutes les musiques prenant la modalité *energy_1* sont dans ce cluster, **81%** des musiques composant le cluster ne sont pas classées dans les charts spotify et **61.9%** ne sont pas classées dans les charts shazam. Malheureusement, ce constat est assez maigre pour émettre des conclusions compte tenu de la taille de ce cluster. D'autres parts, on notera que la plupart des morceaux composant ce cluster sont peu énergiques, peu dansants, peu positifs, et auraient des sonorités très acoustiques.

Individus

Ensuite, on va s'intéresser aux parangons de chaque cluster :

Que disent les parangons ?											
	top_spotify	top_apple	top_deezer	rythme_bpm	danceability	valence	energy	acousticness	instrumentalness	liveness	speechiness
Cluster 1											
1_1	>50	>50	>50	2	3	3	3	1	1	1	1
1_2	>50	Top 50	pas classé	2	3	3	3	1	1	1	1
1_3	Top 20	>50	pas classé	2	3	3	3	1	1	1	1
1_4	pas classé	Top 5	Top 20	2	3	3	3	1	1	1	1
1_5	Top 5	Top 50	pas classé	2	3	3	3	1	1	1	1
Cluster 2											
2_1	Top 5	Top 20	pas classé	4	3	2	3	1	1	1	1
2_2	Top 5	Top 20	pas classé	4	3	3	3	1	1	1	1
2_3	Top 20	>50	Top 20	4	3	3	3	1	1	1	1
2_4	Top 20	>50	Top 5	4	3	3	3	2	1	1	1
2_5	pas classé	pas classé	pas classé	4	3	3	4	1	1	1	1
Cluster 3											
3_1	Top 5	>50	Top 5	2	3	3	3	3	1	4	1
3_2	Top 20	>50	Top 5	3	3	3	4	2	1	4	1
3_3	Top 5	>50	Top 5	3	3	3	4	1	1	4	1
3_4	Top 5	>50	Top 5	2	3	3	4	3	1	4	1
3_5	pas classé	Top 5	pas classé	3	2	2	3	2	1	4	1
Cluster 4											
4_1	Top 50	>50	Top 20	3	3	1	4	1	3	1	1
4_2	pas classé	Top 20	pas classé	1	2	1	2	2	3	1	1
4_3	pas classé	>50	pas classé	1	3	1	2	4	3	1	1
4_4	Top 20	>50	Top 20	3	3	3	4	1	3	1	1
4_5	pas classé	Top 20	pas classé	2	4	3	3	2	3	2	1
Cluster 5											
5_1	pas classé	>50	pas classé	3	2	1	1	4	1	1	1
5_2	pas classé	pas classé	pas classé	3	2	1	1	4	1	1	1
5_3	pas classé	pas classé	pas classé	3	2	1	1	4	1	1	1
5_4	pas classé	Top 50	pas classé	1	3	1	1	4	1	1	1
5_5	>50	>50	Top 50	1	2	1	1	4	1	1	1

La visualisation des parangons est intéressante dans notre classification car on remarque que parmi les parangons du 5^{ème} cluster, les 5 sont des musiques très acoustiques mal classées ou pas classés du tout tandis que les parangons énergiques et enregistrés en direct sont pour la plupart bien classées dans les charts.

Il faut tout de même avoir conscience que les parangons ne sont qu'une infime partie des musiques composant la base de données et ne peuvent pas fournir de conclusion à notre étude.

Conclusion de l'ACM et de la classification

Cette partie de l'étude ne nous aura pas permis d'établir une relation claire entre les caractéristiques musicales et le classement sur les différentes plateformes mais elle nous a permis de définir plusieurs musiques qui se distinguent très nettement dans la base de données, en effet, les musiques très rythmées en terme de bpm, peu énergiques, peu dansantes, ainsi que les morceaux enregistrés en direct, avec beaucoup de mots parlés et les musiques très instrumentales sont rares dans la base de données. Cela sous-entendrait que ce type de musiques à moins de chances de figurer parmi les plus populaire sur spotify ce qui nous fournit un élément de réponse à notre étude.

On n'oubliera pas la légère corrélation négative que l'on ne peut pas pleinement confirmer entre l'acoustique et le classement sur spotify.

Enfin, nous n'avons pas pu établir de lien clair entre la saison de sortie des musiques et leurs caractéristiques ce qui laisserait supposer que le fait de sortir une musique en printemps peut favoriser sa présence dans le haut des classements comme indiqué par l'analyse factorielle des correspondances.

Mais alors quelle est la musique idéale pour plaire aux auditeurs ?

Tout d'abord, nous devons admettre que nous n'avons pas pu déterminer au cours de cette étude, les caractéristiques pertinentes qui permettraient à une musique d'obtenir plus d'écoutes et plus de mises en playlists.

En revanche, d'après nos analyses, nous pouvons recommander aux artistes aspirant à accroître la probabilité que leur musique soit parmi les plus populaires sur Spotify de privilégier des morceaux énergiques, positifs et dansants, tout en conservant un rythme raisonnable. Il est également conseillé de limiter l'ajout excessif d'éléments acoustiques dans leurs compositions. Enfin, favoriser l'usage du chant plutôt que de l'instrumentale est préconisé, tandis qu'une faible inclusion de mots parlés serait préférable.

Enfin, les résultats de l'AFC nous ont indiqué que les artistes devraient songer à sortir leurs musiques pendant la saison printanière au lieu de les sortir à l'automne.

